ReWork.

Dokumen ini bersifat **TERBATAS**. Hanya diperuntukkan bagi **internal** dan **peserta resmi** ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

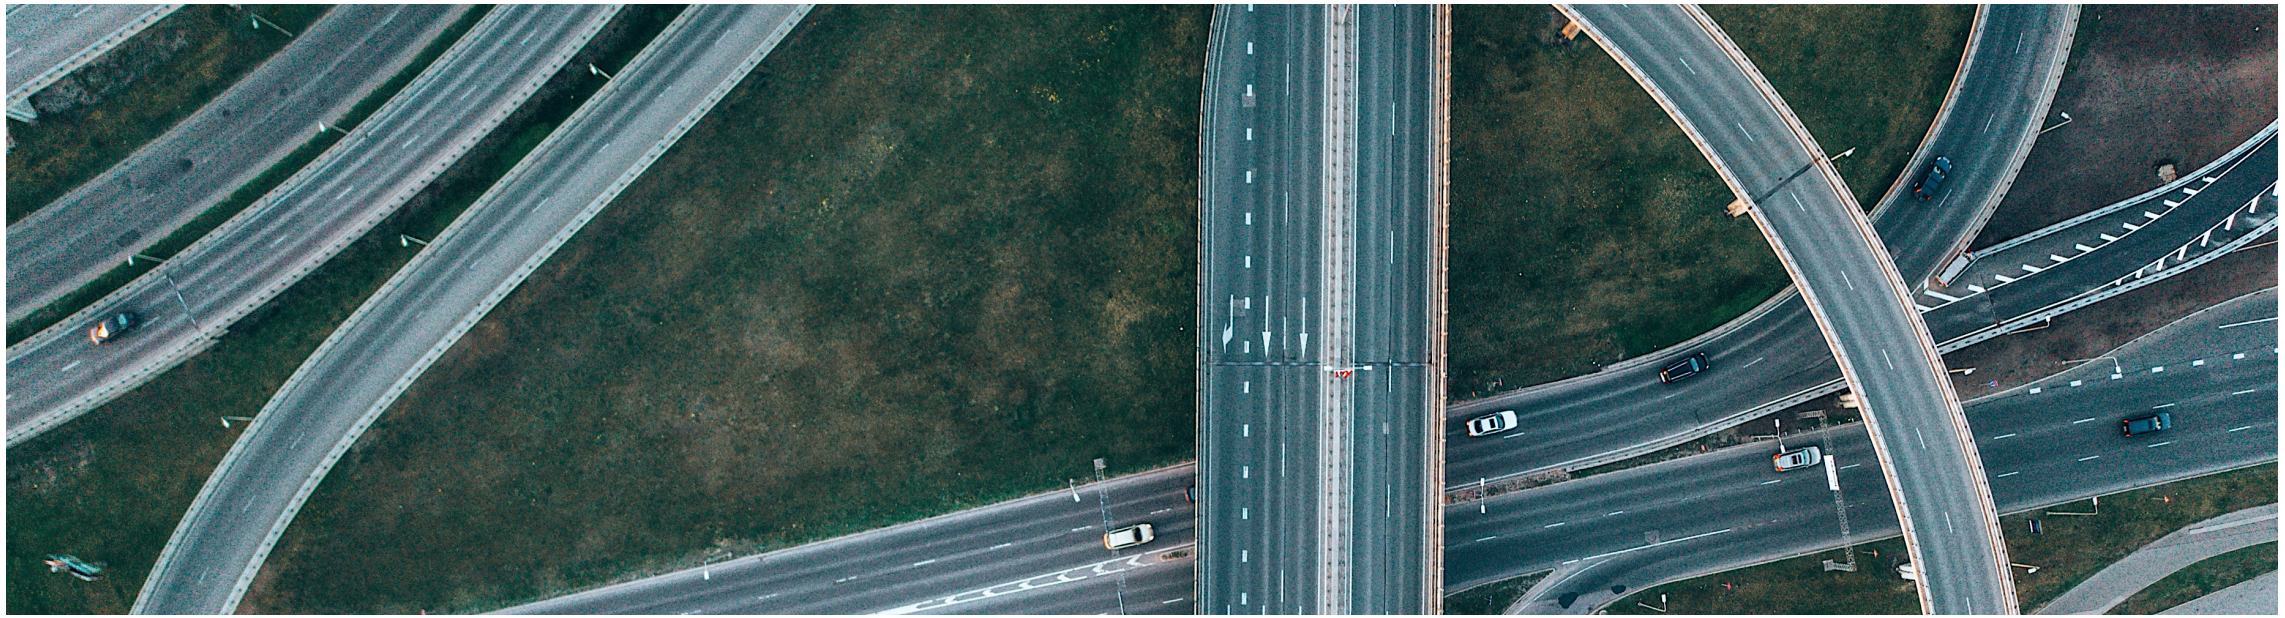

Sesi 06

Transformer Architecture & LLM Fundamentals

Disiapkan oleh Nicholas Dominic, S.Kom., M.Kom.
Terakhir Diperbaharui: Selasa, 27/10/2026 19:30 WIB
Klasifikasi Dokumen: TERBATAS (untuk internal dan peserta)

Transformers are the foundation of modern language models, enabling AI to understand and generate human language.

*This course explores Transformer architecture and the core concepts behind Large **Language Models (LLMs)**, from attention mechanisms to text generation.*

Halo! 😊

NICHOLAS DOMINIC

PENGALAMAN KERJA

- [✓] Senior AI Cloud Solutions & AI Expert, Lintasarta (IOH)
- [✓] Scientific Peer Reviewer, Springer Nature
- [✓] Adjunct AI Researcher, NVIDIA-BINUS AI R&D Center
- Senior Data Scientist, REDComm
- Data Scientist, Agriaku
- IT Specialist/Genomics Data Analyst, Genetics Indonesia
- Corp. Support & Data Analytics Intern, BCA GBKF

PENDIDIKAN

- S2 Binus University – Computer Science (DS), 2020
- S1 Binus University – Computer Science (AI), 2017

SERTIFIKASI INTERNASIONAL

- Technical GenAI Advisor, NVIDIA NPN (2026)
- Cloud NVIDIA Technologies, NVIDIA NPN (2026)
- Data Parallelism, NVIDIA DLI (2025)
- Accelerated Data Science, NVIDIA DLI (2025)
- Deep Learning, NVIDIA DLI (2022)

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

AGENDA BELAJAR HARI INI

1
Natural Language Processing

2
Transformer Architecture & Components

3
Large Language Models

4
Language Models Inference

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

TOPIK 1

Natural Language Processing

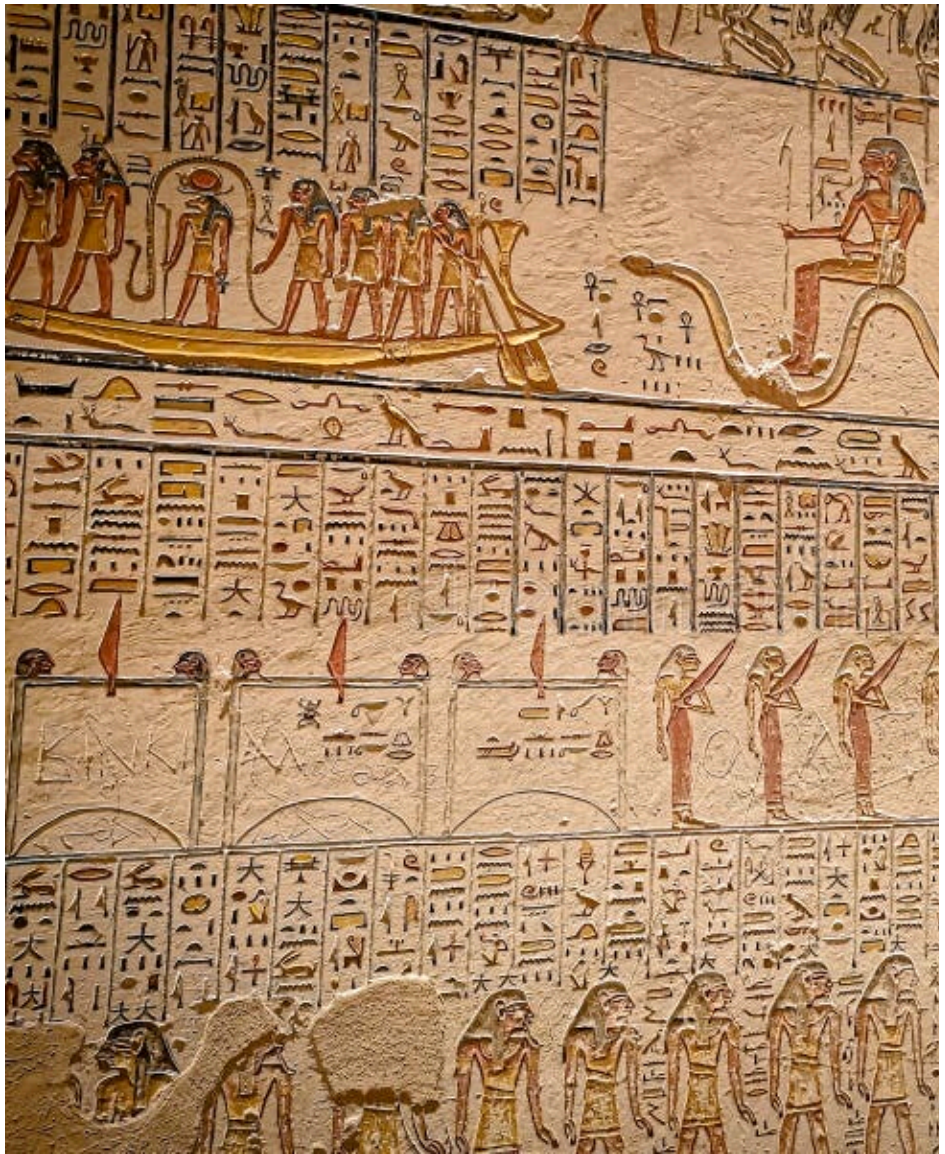

Dokumen ini bersifat **TERBATAS**. Hanya diperuntukkan bagi **internal** dan **peserta resmi** ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Bahasa Tertua di Dunia

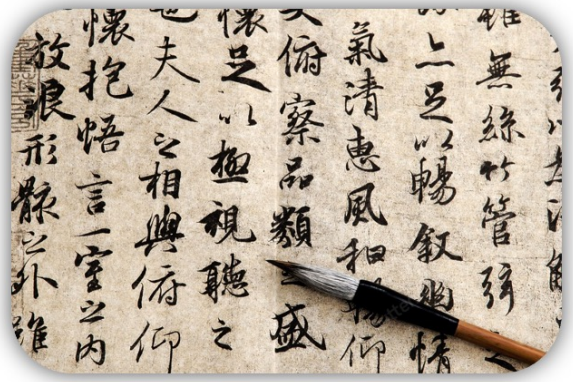

Chinese (~6000 years old)

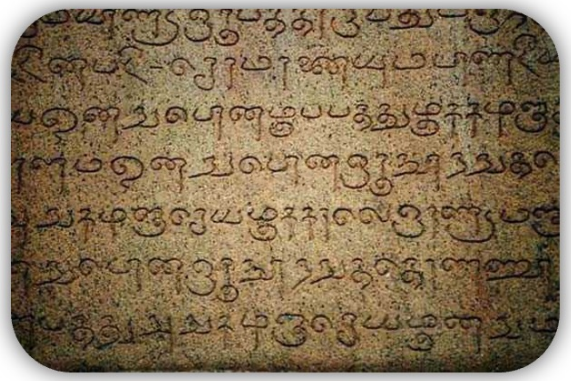

Tamil (~5000 years old)

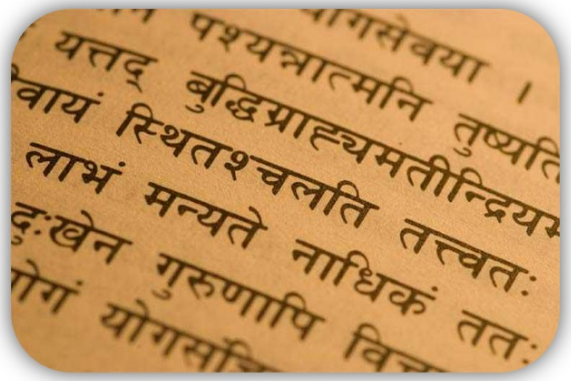

Sanskrit (~5000 years old)

Egyptian (~5000 years old)

Greek (~2900 years old)

Arabic (~1500 years old)

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Tetapi ...

apa yang
membuat
bahasa
menjadi
“**bahasa**”?

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat **TERBATAS**. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Komponen Sebuah Bahasa

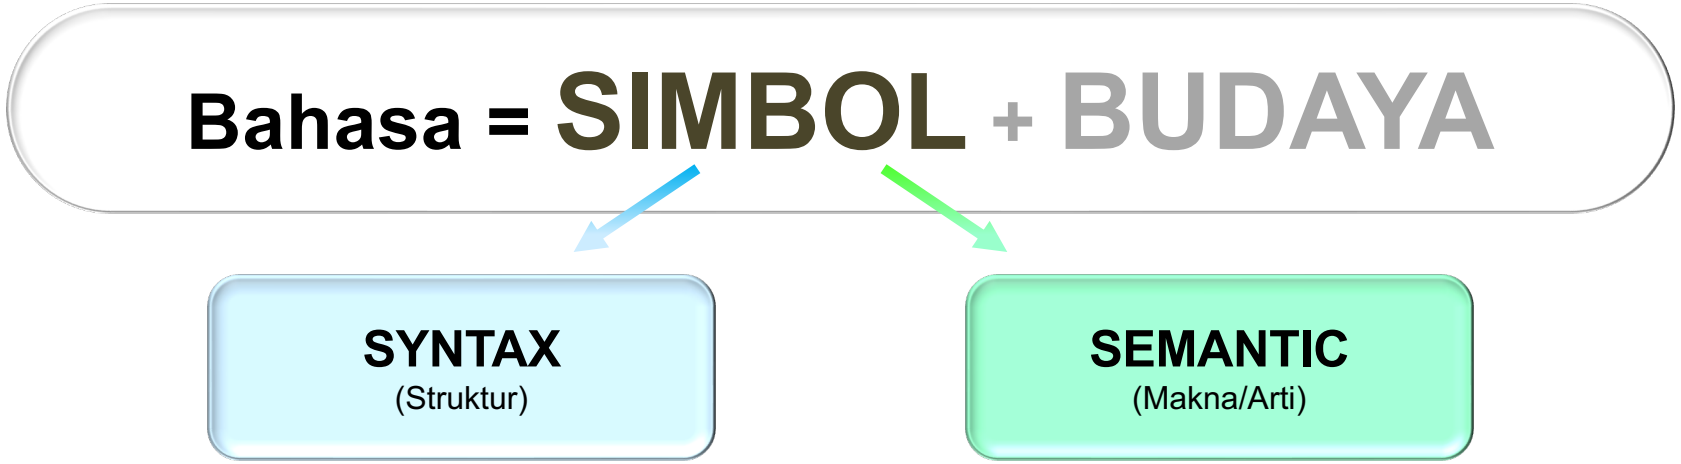

C O N T O H

✓ syntax	✗ semantic	"Waktu dan tempat saya persilakan."
✗ syntax	✓ semantic	"*Where you going?*"
✓ syntax	✓ semantic	"Hari ini, matahari bersinar terang."
✗ syntax	✗ semantic	"*Sleep the car blue now.*"

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Domain dari NLP

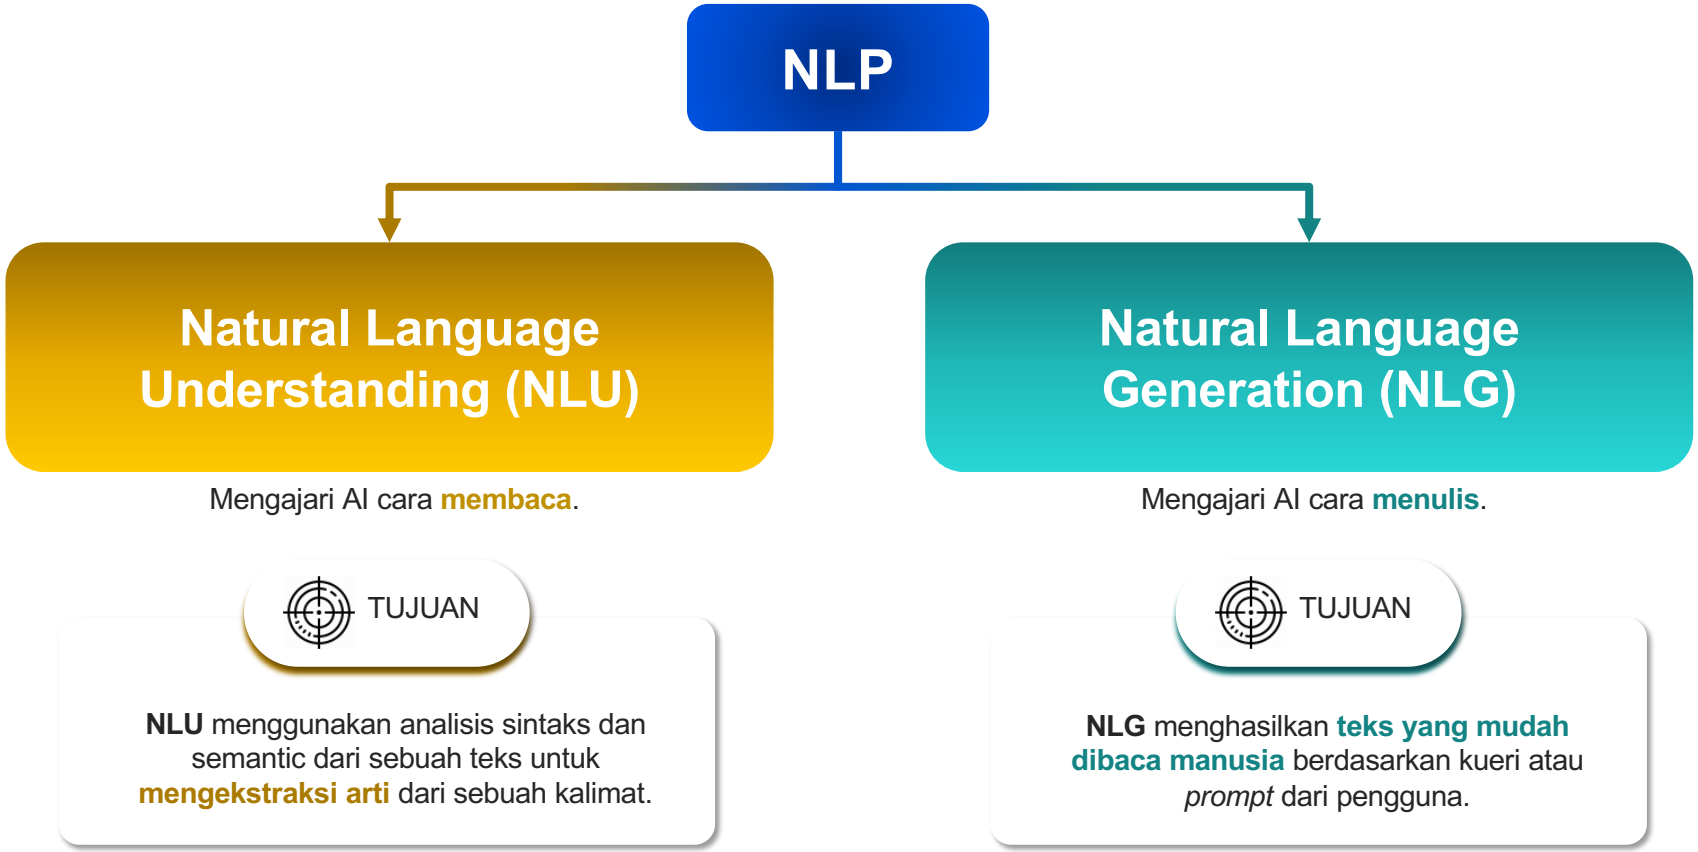

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Contoh NLU

Information Retrieval

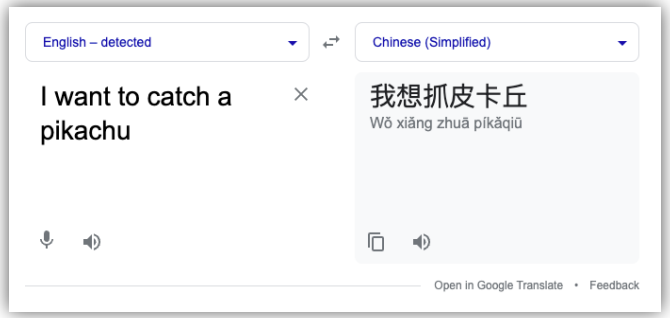

Language Translation

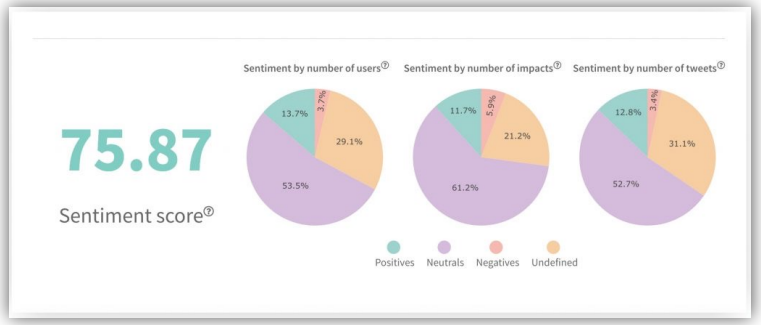

Sentiment Analysis

Voice Assistant

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Contoh NLG

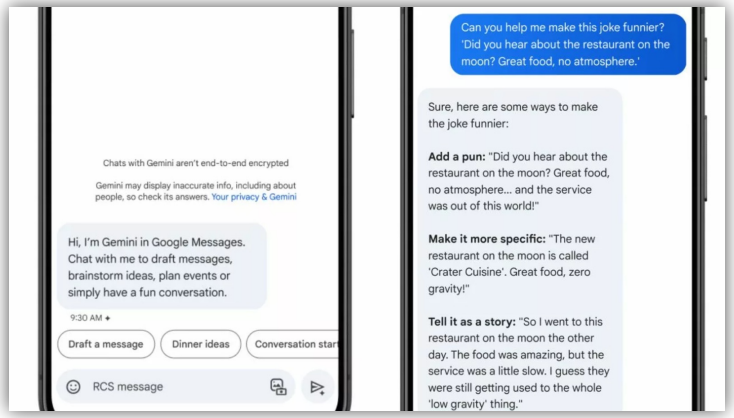

Text or Content Generation

ChatGPT 6 (OpenAI)
Gemini Pro (Google)
Llama-4 (Meta)
Claude 5.5 (Anthropic)

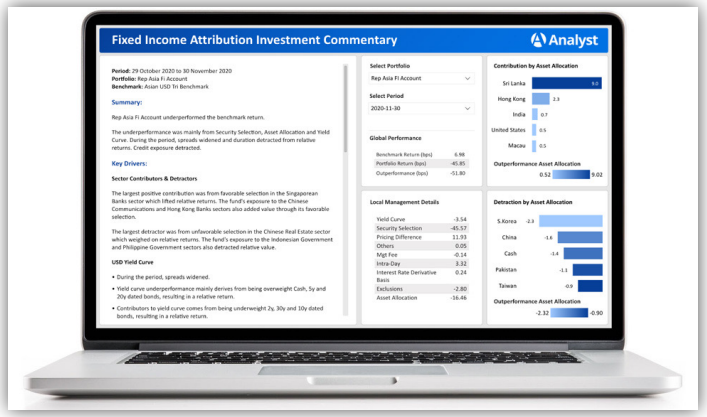

Automated Reporting

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Cara Memproses Teks (1/2)

Raw Text → **Normalization** → Stemming

- Tokenisasi

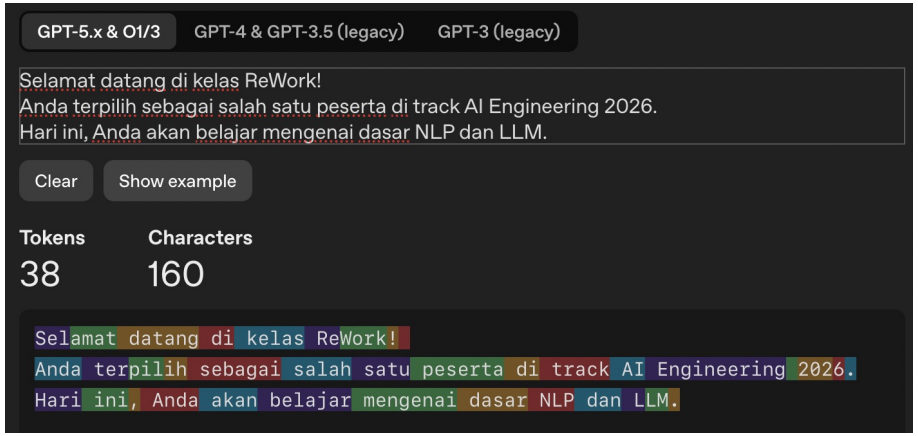

- Mengubah huruf menjadi huruf kecil dan/atau huruf besar
- Menghapus emoji dan spasi berlebih
- Menghapus tautan atau alamat situs web
- Menghapus nama pengguna yang diawali dengan simbol @
- Menghapus tagar yang diawali dengan simbol #
- Menghapus karakter yang berulang
- ... dll.

```python
def text_preproc(text : str, *args, **kwargs) -> str:
    # 1. TEXT NORMALIZATION
    # case folding (all to lower case)
    text = text.lower()

    # remove emoji
    emoji_pattern = re.compile("["
        u"\U0001F600-\U0001F64F"  # emoticons
        u"\U0001F300-\U0001F5FF"  # symbols & pictographs
        u"\U0001F680-\U0001F6FF"  # transport & map symbols
        u"\U0001F1E0-\U0001F1FF"  # flags (iOS)
        u"\U00002500-\U00002BEF"  # chinese char
        u"\U00002702-\U000027B0"
        u"\U00002702-\U000027B0"
        u"\U000024C2-\U0001F251"
        u"\U0001f926-\U0001f937"
        u"\U00010000-\U0010ffff"
    "]+", flags=re.UNICODE)
    text = emoji_pattern.sub(r'', text)

    # remove URL, username (@), and hashtag (#)
    text = re.sub(r"(?:\@|\#|https?\://)\S+", "", text)

    # remove repeated characters (character normalization)
    text = re.sub(r'([A-Za-z])\1{2,}', r'\1', text)

    # remove punctuations (. , ! ...)
    text = re.compile('[%s]' % re.escape(string.punctuation)).sub('', text)

    # remove excess spaces
    text = re.sub('\s+', ' ', text) # for spaces in between
    text = text.lstrip().rstrip()

    # 2. Lemmatization / Stemming
    factory = idStemmer()
    stemmer = factory.create_stemmer()

    text = stemmer.stem(text)

    return text
```

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Cara Memproses Teks (2/2)

Raw Text → Normalization → **Stemming**

- Gunakan *stopwords* yang sesuai (bahasa Inggris, bahasa Indonesia, dll).

- Stemming vs. Lemmatization
  - **Stemming:** Menghapus suffix (akhiran) dari kata. Metode ini berbasis aturan (*rule-based*), lebih cepat, tetapi kurang akurat.
  - **Lemmatization:** Menentukan apakah dua kata memiliki root (akar kata) yang sama melalui analisis morfologi secara menyeluruh (*complete morphological parsing*). Metode ini berbasis kamus (*dictionary-based*), lebih lambat, tetapi lebih akurat.

```python
def text_preproc(text : str, *args, **kwargs) -> str:
    # 1. TEXT NORMALIZATION
    # case folding (all to lower case)
    text = text.lower()

    # remove emoji
    emoji_pattern = re.compile("["
        u"\U0001F600-\U0001F64F"  # emoticons
        u"\U0001F300-\U0001F5FF"  # symbols & pictographs
        u"\U0001F680-\U0001F6FF"  # transport & map symbols
        u"\U0001F1E0-\U0001F1FF"  # flags (iOS)
        u"\U00002500-\U00002BEF"  # chinese char
        u"\U00002702-\U000027B0"
        u"\U00002702-\U000027B0"
        u"\U000024C2-\U0001F251"
        u"\U0001f926-\U0001f937"
        u"\U00010000-\U0010ffff"
    "]+", flags=re.UNICODE)
    text = emoji_pattern.sub(r'', text)

    # remove URL, username (@), and hashtag (#)
    text = re.sub(r"(?:\@|\#|https?\://)\S+", "", text)

    # remove repeated characters (character normalization)
    text = re.sub(r'([A-Za-z])\1{2,}', r'\1', text)

    # remove punctuations (. , ! ...)
    text = re.compile('[%s]' % re.escape(string.punctuation)).sub('', text)

    # remove excess spaces
    text = re.sub('\s+', ' ', text) # for spaces in between
    text = text.lstrip().rstrip()

    # 2. Lemmatization / Stemming
    factory = idStemmer()
    stemmer = factory.create_stemmer()

    text = stemmer.stem(text)

    return text
```

[4]

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

ncijsklwiemrarisqskbccoqp
gasdlqiwaiwlelpydjfgjfdghj
blysqtextmnwmiasdkwejwl
rcukslwvectorizationksdup
apcvcskdwpridobzmskwog
litseyskqcsekaavbwuetsqtj

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Dari Kata ke Representasi Numerik

Mesin tidak memahami teks. Oleh karena itu, kita perlu mengubah **teks** menjadi **representasi numerik** yang bermakna melalui proses vektorisasi (atau embedding).

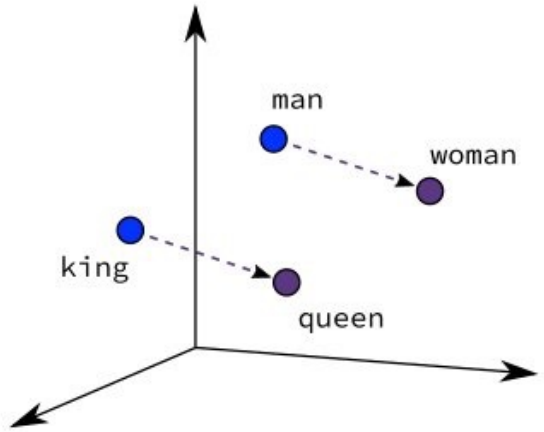

Male-Female

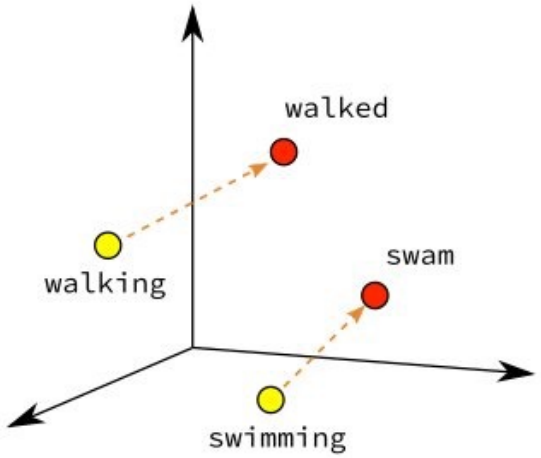

Verb Tense

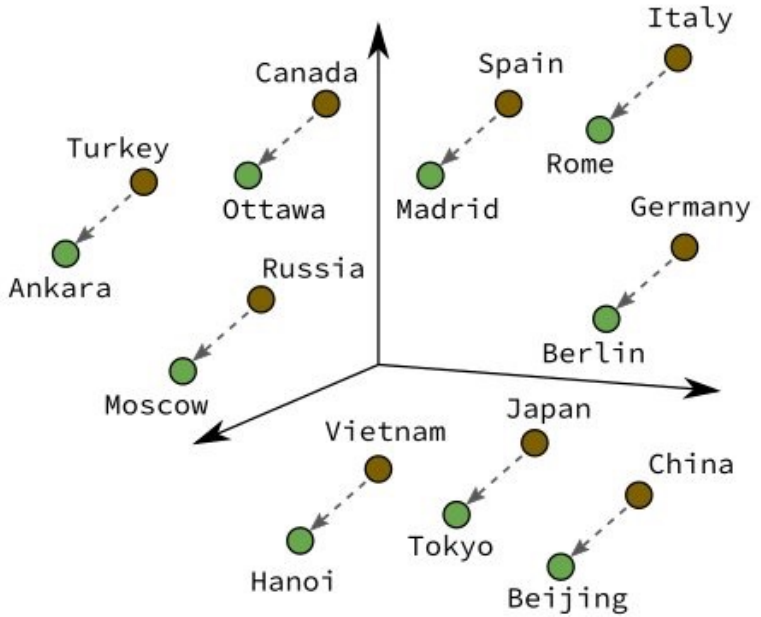

Country-Capital

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Teknik Vektorisasi (1/6)

One-hot encoding (OHE) menawarkan kesederhanaan dalam mengubah variabel kategorikal menjadi input numerik.

Namun, OHE memiliki kelemahan berupa *sparsity* dan *curse of dimensionality*, sehingga OHE membutuhkan banyak memori.

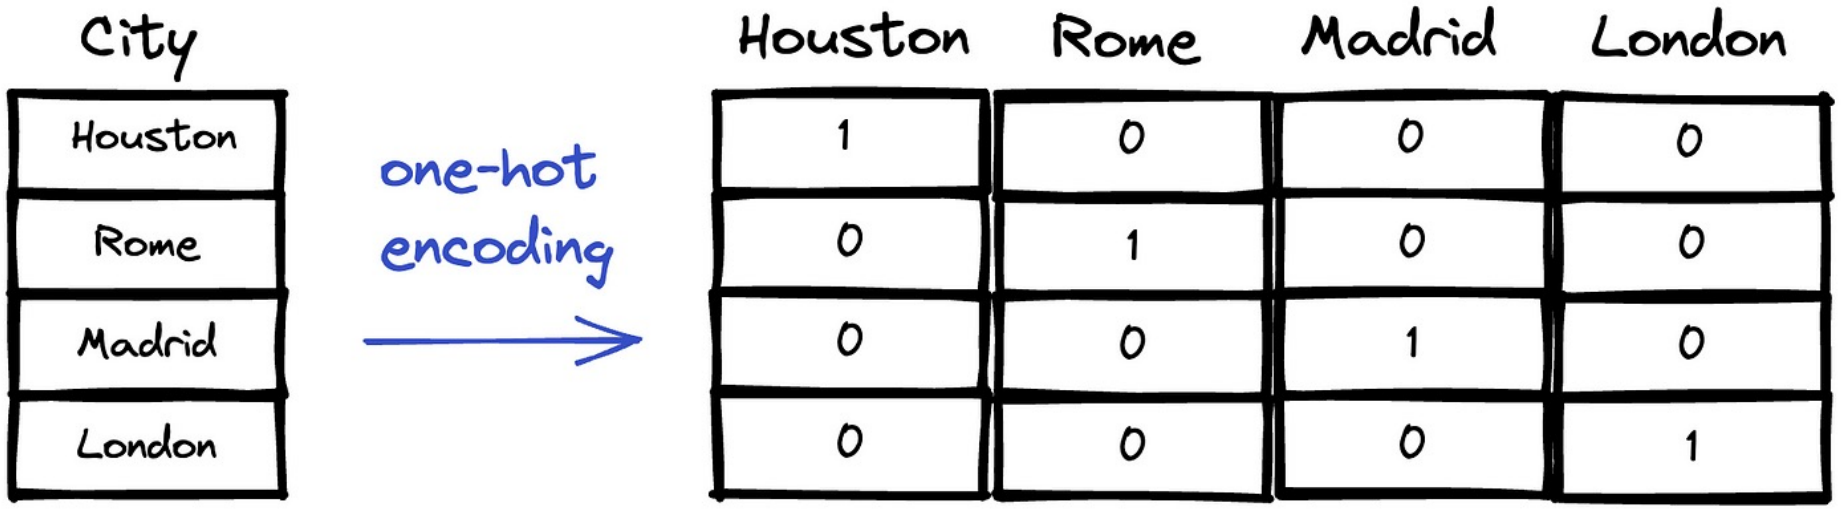

- One-hot Encoding
- Bag-of-Words
- TF-IDF
- Word2Vec
- Auto-Encoder
- Contextual Embedding

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Teknik Vektorisasi (2/6)

Bag-of-Words (BoW) **menghitung frekuensi** setiap kata (tanpa memperhatikan urutan kata). Ada dua cara untuk menggunakan BoW:

Representing the sentence, "it is the best of the best "

It	is	the	best	of	a	an
[1	,1	,1	,1	,1	,0	,0]

(only the words present in the document are activated)

(or)

[1	,1	,2	,2	,1	,0	,0]

(the word count is taken into consideration instead of activation)

- One-hot Encoding
- Bag-of-Words
- TF-IDF
- Word2Vec
- Auto-Encoder
- Contextual Embedding

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Teknik Vektorisasi (3/6)

Term Frequency – Inverse Document Frequency (TF-IDF) dapat dihitung dengan rumus:

$$w_{x,y} = tf_{x,y} \times \log\left(\frac{N}{df_x}\right)$$

Frequency of a word within the document

Frequency of a word across the documents

	di	t	tc	tt	tf	df	idf	tfidf
0	0	the	2	7	0.285714	2	0.000000	0.000000
1	0	car	1	7	0.142857	1	0.176091	0.025156
2	0	is	1	7	0.142857	2	0.000000	0.000000
3	0	driven	1	7	0.142857	2	0.000000	0.000000
4	0	on	1	7	0.142857	2	0.000000	0.000000
5	0	road	1	7	0.142857	1	0.176091	0.025156
6	1	the	2	7	0.285714	2	0.000000	0.000000
7	1	truck	1	7	0.142857	1	0.176091	0.025156
8	1	is	1	7	0.142857	2	0.000000	0.000000
9	1	driven	1	7	0.142857	2	0.000000	0.000000
10	1	on	1	7	0.142857	2	0.000000	0.000000
11	1	highway	1	7	0.142857	1	0.176091	0.025156

- One-hot Encoding
- Bag-of-Words
- TF-IDF
- Word2Vec
- Auto-Encoder
- Contextual Embedding

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Teknik Vektorisasi (4/6)

Berbeda dengan One-hot Encoding (OHE) dan Bag-of-Words (BoW), **Word2Vec dapat menangkap kemiripan makna antarkata**. Kata-kata yang memiliki makna atau konteks serupa cenderung memiliki representasi vektor yang berdekatan dalam ruang vektor. Word2Vec memiliki dua arsitektur utama:

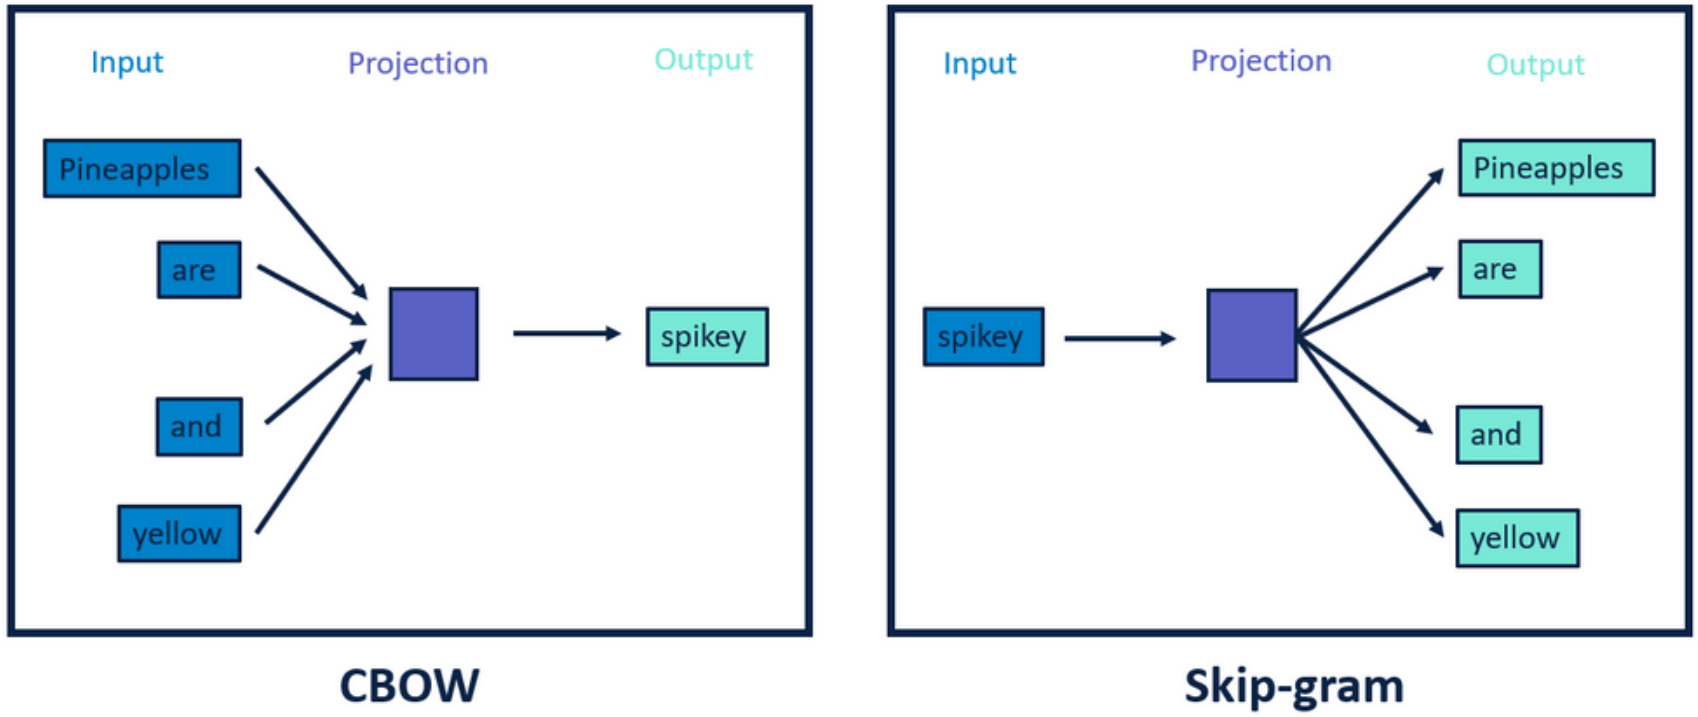

- One-hot Encoding
- Bag-of-Words
- TF-IDF
- **Word2Vec**
- Auto-Encoder
- Contextual Embedding

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Teknik Vektorisasi (5/6)

Autoencoder adalah neural network yang digunakan untuk mempelajari representasi numerik (vector embeddings) dari teks dengan cara **mengompresi input** menjadi representasi berdimensi lebih rendah (*encoding*), kemudian merekonstruksi input tersebut melalui proses *decoding*.

Dalam konteks text vectorization, *encoder* menghasilkan **vektor yang menangkap pola dan informasi penting dari teks**, sedangkan *decoder* berusaha merekonstruksi teks asli dari vektor tersebut.

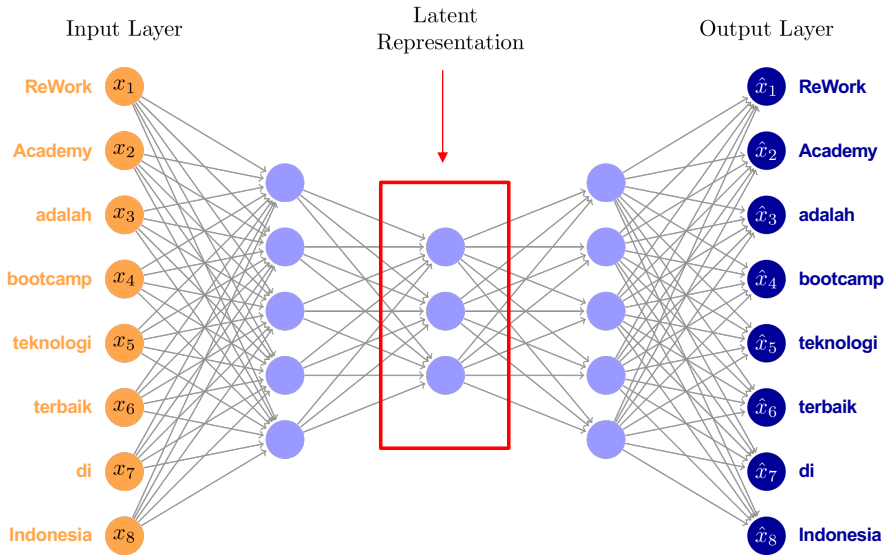

- One-hot Encoding
- Bag-of-Words
- TF-IDF
- Word2Vec
- Auto-Encoder
- Contextual Embedding

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Teknik Vektorisasi (6/6)

Bidirectional Encoder Representations from Transformers (BERT) mengodekan konteks secara bidirectional (dua arah), berbeda dengan RNN yang bersifat directional (satu arah), serta hanya memerlukan sedikit perubahan arsitektur untuk berbagai kasus NLP.

Pertanyaan:
Apa tujuan dari token **embeddings**, **segment embeddings**, dan **positional embeddings**?

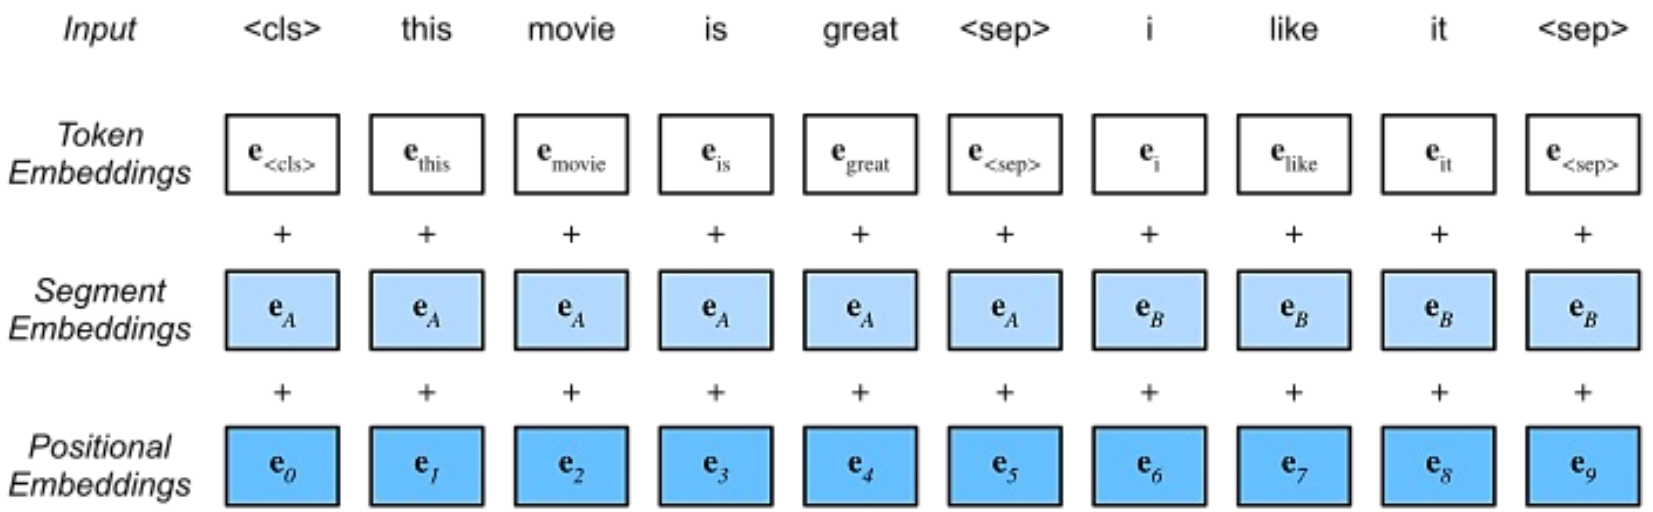

One-hot Encoding

Bag-of-Words

TF-IDF

Word2Vec

Auto-Encoder

Contextual Embedding

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Ada pertanyaan?

Dokumen ini bersifat **TERBATAS**. Hanya diperuntukkan bagi **internal** dan **peserta resmi** ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

TOPIK 2

Transformer Architecture & Components

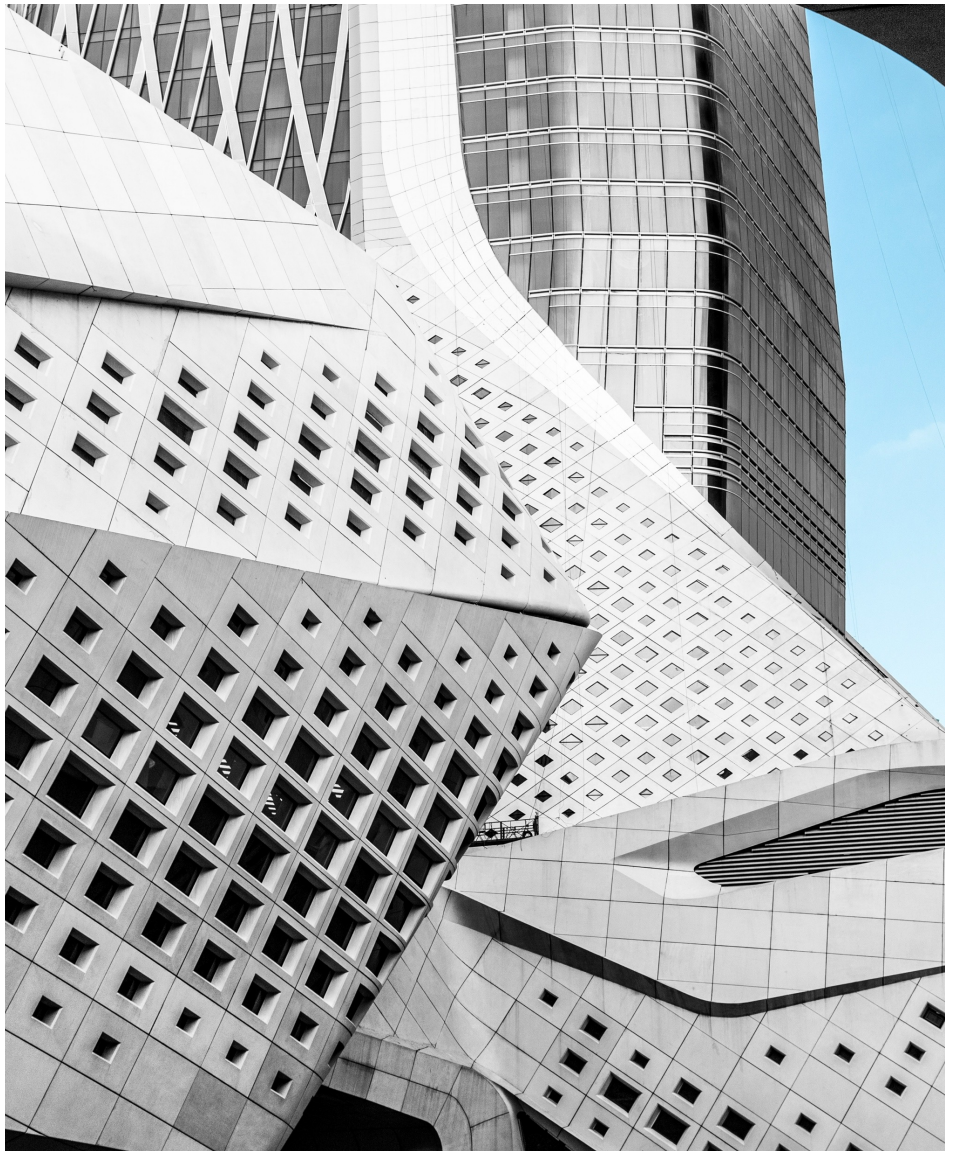

Dokumen ini bersifat **TERBATAS**. Hanya diperuntukkan bagi **internal** dan **peserta resmi** ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Model Prediksi Kata Sebelum Transformer

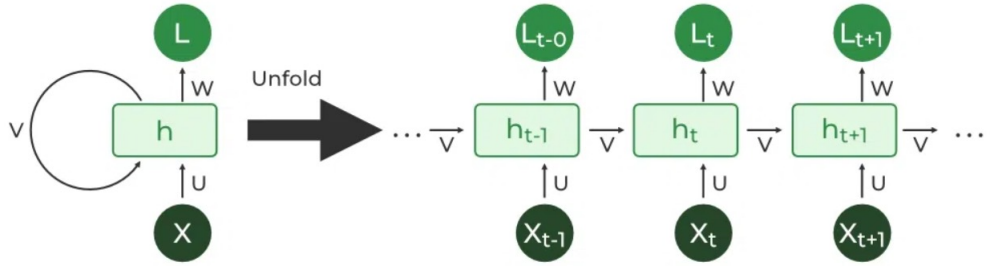

RECURRENT NEURAL NETWORK

- Hidden state berfungsi sebagai “memori RNN” yang menyimpan informasi dari data sebelumnya.
- Pada forward pass, input dan hidden state sebelumnya digabungkan menjadi sebuah vektor.
- Meskipun demikian, RNN masih memiliki masalah berupa (1) short-term memory dan (2) vanishing gradient.

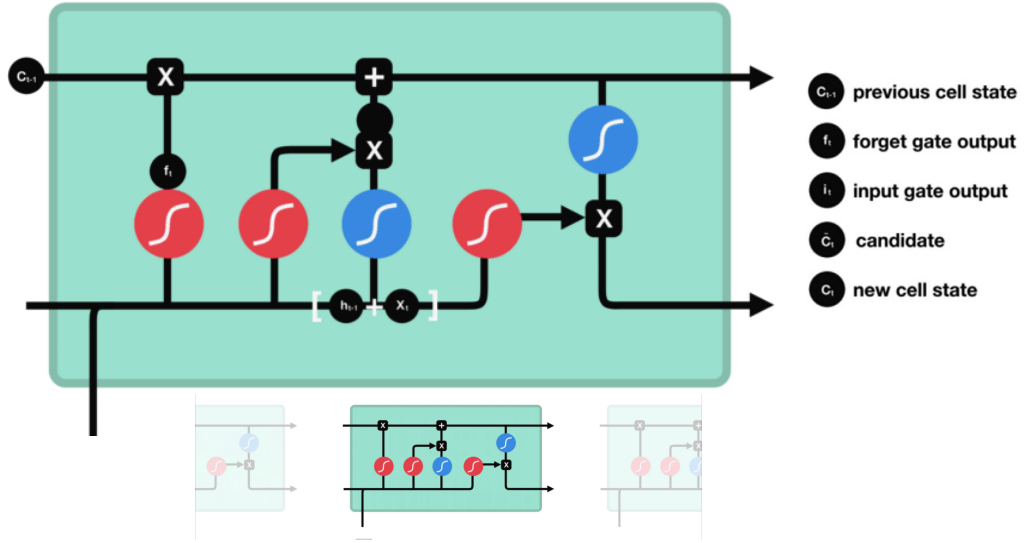

LONG SHORT-TERM MEMORY

- LSTM memiliki empat **gate** (neural network berbeda).
  - Forget gate → informasi apa yang perlu dipertahankan/dilupakan?
  - Input gate → informasi mana yang penting?
  - Cell gate → informasi mana yang masih relevan?
  - Output gate → bagaimana hidden state berikutnya?
- Alternatif: **Gated Recurrent Unit (GRU).**

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Transformer = Attention! 🚨

Attention Is All You Need

Ashish Vaswani* Google Brain avaswani@google.com

Noam Shazeer* Google Brain noam@google.com

Niki Parmar* Google Research nikip@google.com

Jakob Uszkoreit* Google Research usz@google.com

Llion Jones* Google Research llion@google.com

Aidan N. Gomez* † University of Toronto aidan@cs.toronto.edu

Łukasz Kaiser* Google Brain lukaszkaiser@google.com

Illia Polosukhin* ‡ illia.polosukhin@gmail.com

Abstract

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to be superior in quality while being more parallelizable and requiring significantly less time to train. Our model achieves 28.4 BLEU on the WMT 2014 English-to-German translation task, improving over the existing best results, including ensembles, by over 2 BLEU. On the WMT 2014 English-to-French translation task, our model establishes a new single-model state-of-the-art BLEU score of 41.0 after training for 3.5 days on eight GPUs, a small fraction of the training costs of the best models from the literature.

Sumber Artikel Ilmiah:
https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf

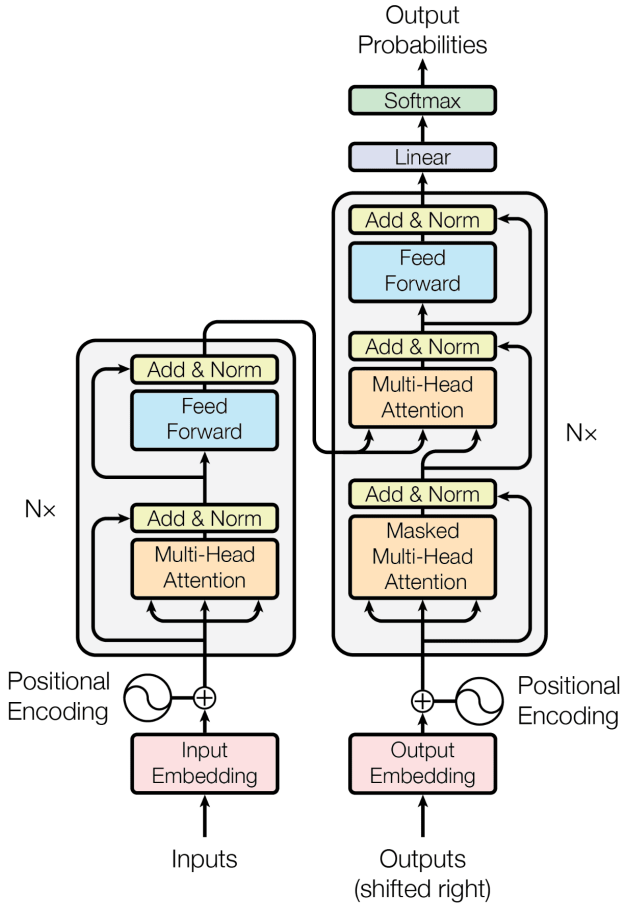

Komponen inti yang akan kita bahas:

1. Positional Encoding
2. Multi-Head Attention

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

#1. Positional Encoding

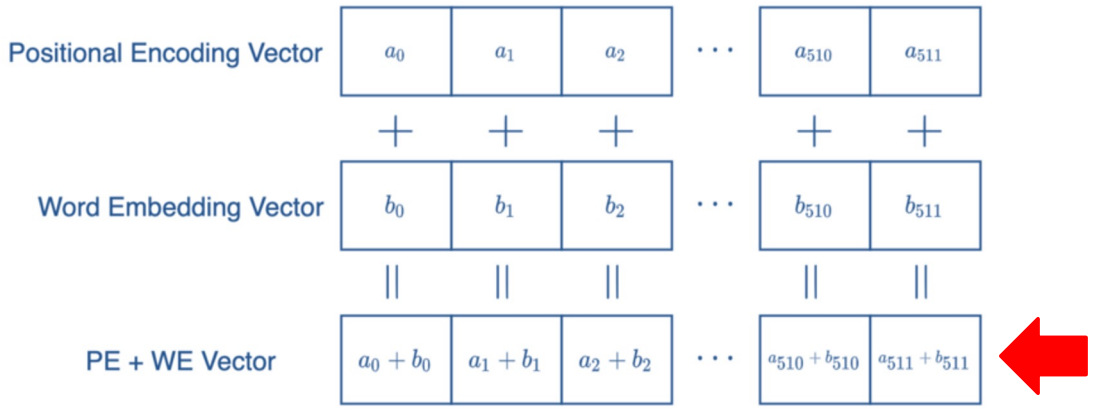

- **Attention layer** pada Transformer menghitung setiap token (3/4 kata) secara independen, sehingga konteks urutan kata menjadi hilang.
  - Berbeda dengan recurrent model seperti RNN dan LSTM, Transformer (dan non-recurrent model lainnya) tidak memiliki mekanisme bawaan untuk menangkap posisi relatif kata dalam sebuah kalimat.
  - Padahal, lokasi (indeks) dan jarak antarkata memberikan informasi kontekstual.

- Vektor **Positional Encoding (PE)** dibuat agar memiliki ukuran yang sama dengan vektor Word Embedding (WE) untuk setiap kata. Setelah dihitung, vektor Positional Encoding ditambahkan ke vektor embedding (PE + WE).
  - Dengan demikian, setiap token memiliki representasi yang unik dan informasi posisinya tetap dapat dikenali, meskipun urutan token diubah.
  - Dengan Positional Encoding, Transformer menjadi permutation invariant.

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

#2. Multi-Head Attention

- **Multi-Head Attention** merupakan penggabungan dari **beberapa self-attention.** Oleh karena itu, setiap attention head dapat dijalankan secara paralel (menggunakan GPU/worker yang berbeda).
  - Setiap "head" menerima input yang sama. Tujuannya, agar Transformer dapat mempelajari berbagai representasi secara bersamaan melalui attention weights dan biases yang berbeda.

- Lalu, apa itu **Self-Attention**? Perhatikan contoh berikut:

1 *The animal didn't cross the street because it was too tired.*
L'animal n'a pas traversé la rue parce qu'il était trop fatigué.

2 *The animal didn't cross the street because it was too wide.*
L'animal n'a pas traversé la rue parce qu'elle était trop large.

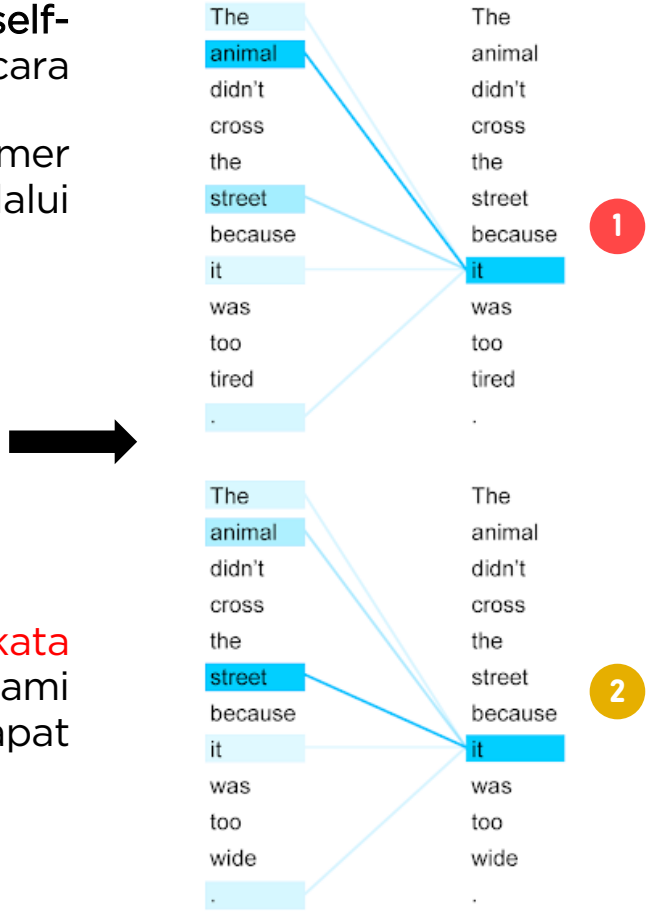

- Jadi, **Self-Attention** adalah mekanisme yang memungkinkan setiap kata memperhatikan kata-kata lain dalam suatu kalimat untuk memahami konteks dan hubungan antarkata, sehingga makna setiap kata dapat dipahami berdasarkan kata-kata di sekitarnya.

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Visualisasi Mekanisme Self-Attention

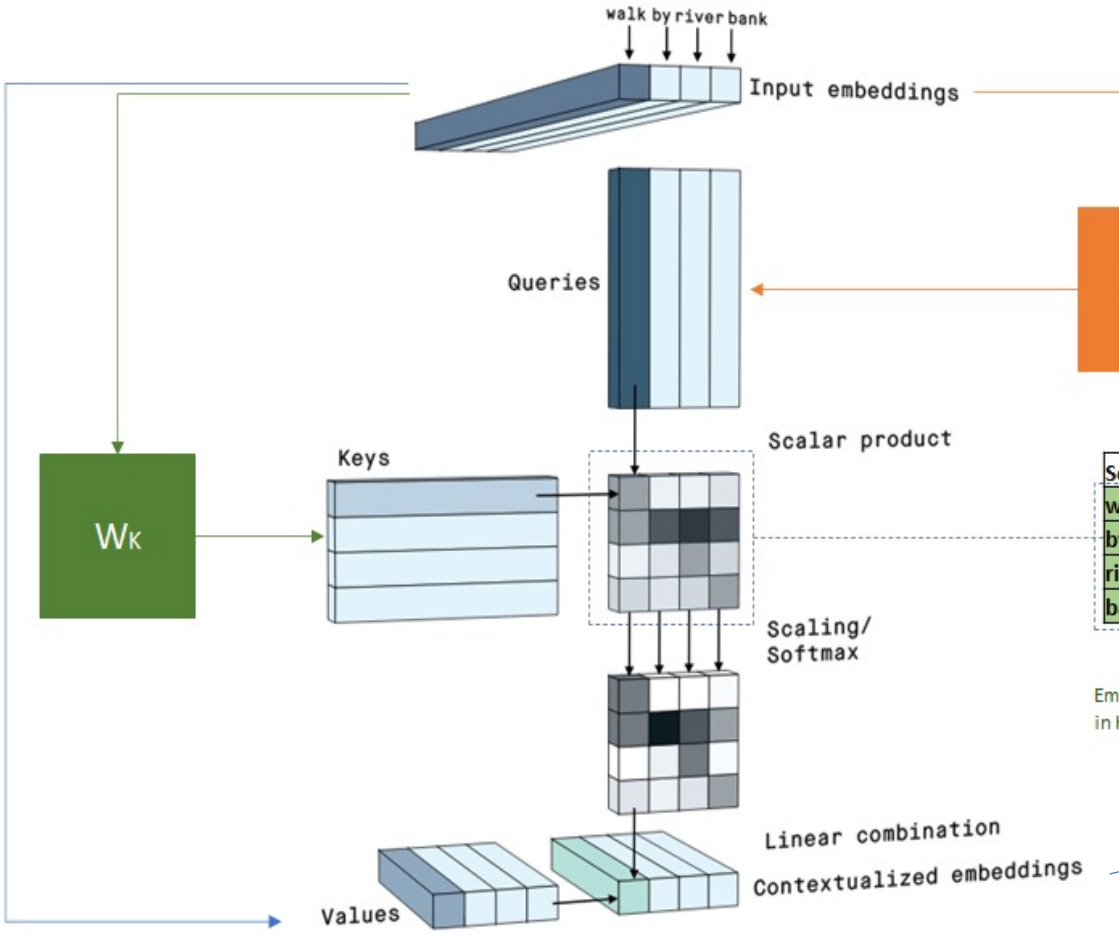

Embedded tensor in Q space

Self Attention	walk	by	river	bank
walk	0.88	0.1	0.21	0.12
by	0.08	0.8	0.12	0.14
river	0.03	0.14	0.83	0.7
bank	0.01	0.01	0.4	0.77

Embedded tensor in K space

- Operasi attention dapat dipahami sebagai proses **Information Retrieval (IR)**, yang melibatkan Query (Q), Key (K), dan Value (V).

- Output dari self-attention adalah contextualized embeddings, yaitu representasi kata yang telah diperkaya dengan informasi konteks dari kata-kata lainnya.

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Contoh Perhitungan Self-Attention

1 Tokenisasi dan Embedding

Kalimat: "Selamat datang di ReWork Academy"

Token dipecah menjadi 5 kata dan diubah menjadi vektor embedding berdimensi 4 (contoh nilai).

Token	Embedding (d = 4)
Selamat	[0.10, 0.20, 0.30, 0.40]
datang	[0.20, 0.10, 0.40, 0.30]
di	[0.30, 0.40, 0.20, 0.10]
ReWork	[0.50, 0.30, 0.20, 0.10]
Academy	[0.40, 0.20, 0.10, 0.30]

(d = 4, contoh nilai)

2 Hitung Query, Key, Value

Gunakan matriks proyeksi sederhana (ukuran 4 × 4) untuk mendapatkan Q, K, V.

$$W_Q = \begin{bmatrix} 0.5 & 0.1 & 0.0 & 0.0 \\ 0.0 & 0.5 & 0.1 & 0.0 \\ 0.0 & 0.0 & 0.5 & 0.1 \\ 0.1 & 0.0 & 0.0 & 0.5 \end{bmatrix} \quad W_K = \begin{bmatrix} 0.5 & 0.0 & 0.1 & 0.0 \\ 0.0 & 0.5 & 0.0 & 0.1 \\ 0.1 & 0.0 & 0.5 & 0.0 \\ 0.0 & 0.1 & 0.0 & 0.5 \end{bmatrix} \quad W_V = \begin{bmatrix} 0.5 & 0.1 & 0.0 & 0.0 \\ 0.1 & 0.5 & 0.1 & 0.0 \\ 0.0 & 0.1 & 0.5 & 0.1 \\ 0.0 & 0.0 & 0.1 & 0.5 \end{bmatrix}$$

$$Q = XW_Q \qquad K = XW_K \qquad V = XW_V$$

(X adalah matriks embedding berukuran 5 × 4)

3 Hitung Skor Attention

Hitung dot product antara Q dan K^T, lalu bagi dengan $\sqrt{d}$ ($d = 4$).

$$Skor = \frac{QK^T}{\sqrt{d}} = \frac{QK^T}{2}$$

Hasil skor (5 × 5):

$$\begin{bmatrix} 0.07 & 0.06 & 0.06 & 0.10 & 0.09 \\ 0.06 & 0.06 & 0.05 & 0.08 & 0.07 \\ 0.06 & 0.05 & 0.07 & 0.08 & 0.07 \\ 0.10 & 0.08 & 0.08 & 0.12 & 0.11 \\ 0.09 & 0.07 & 0.07 & 0.11 & 0.10 \end{bmatrix}$$

4 Normalisasi dengan Softmax

Ubah skor menjadi bobot perhatian (attention weight) untuk setiap token.

$$\alpha_i = \frac{\exp(score_i)}{\sum_j \exp(score_j)}$$

Hasil attention weight (5 × 5):

$$\begin{bmatrix} 0.19 & 0.18 & 0.17 & 0.24 & 0.22 \\ 0.18 & 0.19 & 0.16 & 0.23 & 0.20 \\ 0.17 & 0.15 & 0.21 & 0.23 & 0.21 \\ 0.18 & 0.16 & 0.16 & 0.27 & 0.23 \\ 0.17 & 0.15 & 0.16 & 0.26 & 0.26 \end{bmatrix}$$

5 Kalikan dengan Value

Kalikan bobot perhatian dengan matriks V untuk mendapatkan representasi kontekstual.

Output (5 × 4):

$$\begin{bmatrix} 0.18 & 0.16 & 0.13 & 0.19 \\ 0.16 & 0.14 & 0.11 & 0.17 \\ 0.15 & 0.17 & 0.13 & 0.16 \\ 0.22 & 0.19 & 0.15 & 0.22 \\ 0.20 & 0.17 & 0.13 & 0.20 \end{bmatrix}$$

6 Hasil: Contextualized Embeddings

Setiap token sekarang memiliki representasi baru yang sudah mempertimbangkan konteks kata lain dalam kalimat.

Output akhir (5 × 4):

Selamat	[0.18, 0.16, 0.13, 0.19]
datang	[0.16, 0.14, 0.11, 0.17]
di	[0.15, 0.17, 0.13, 0.16]
ReWork	[0.22, 0.19, 0.15, 0.22]
Academy	[0.20, 0.17, 0.13, 0.20]

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

“Keluarga” dari Model Transformer

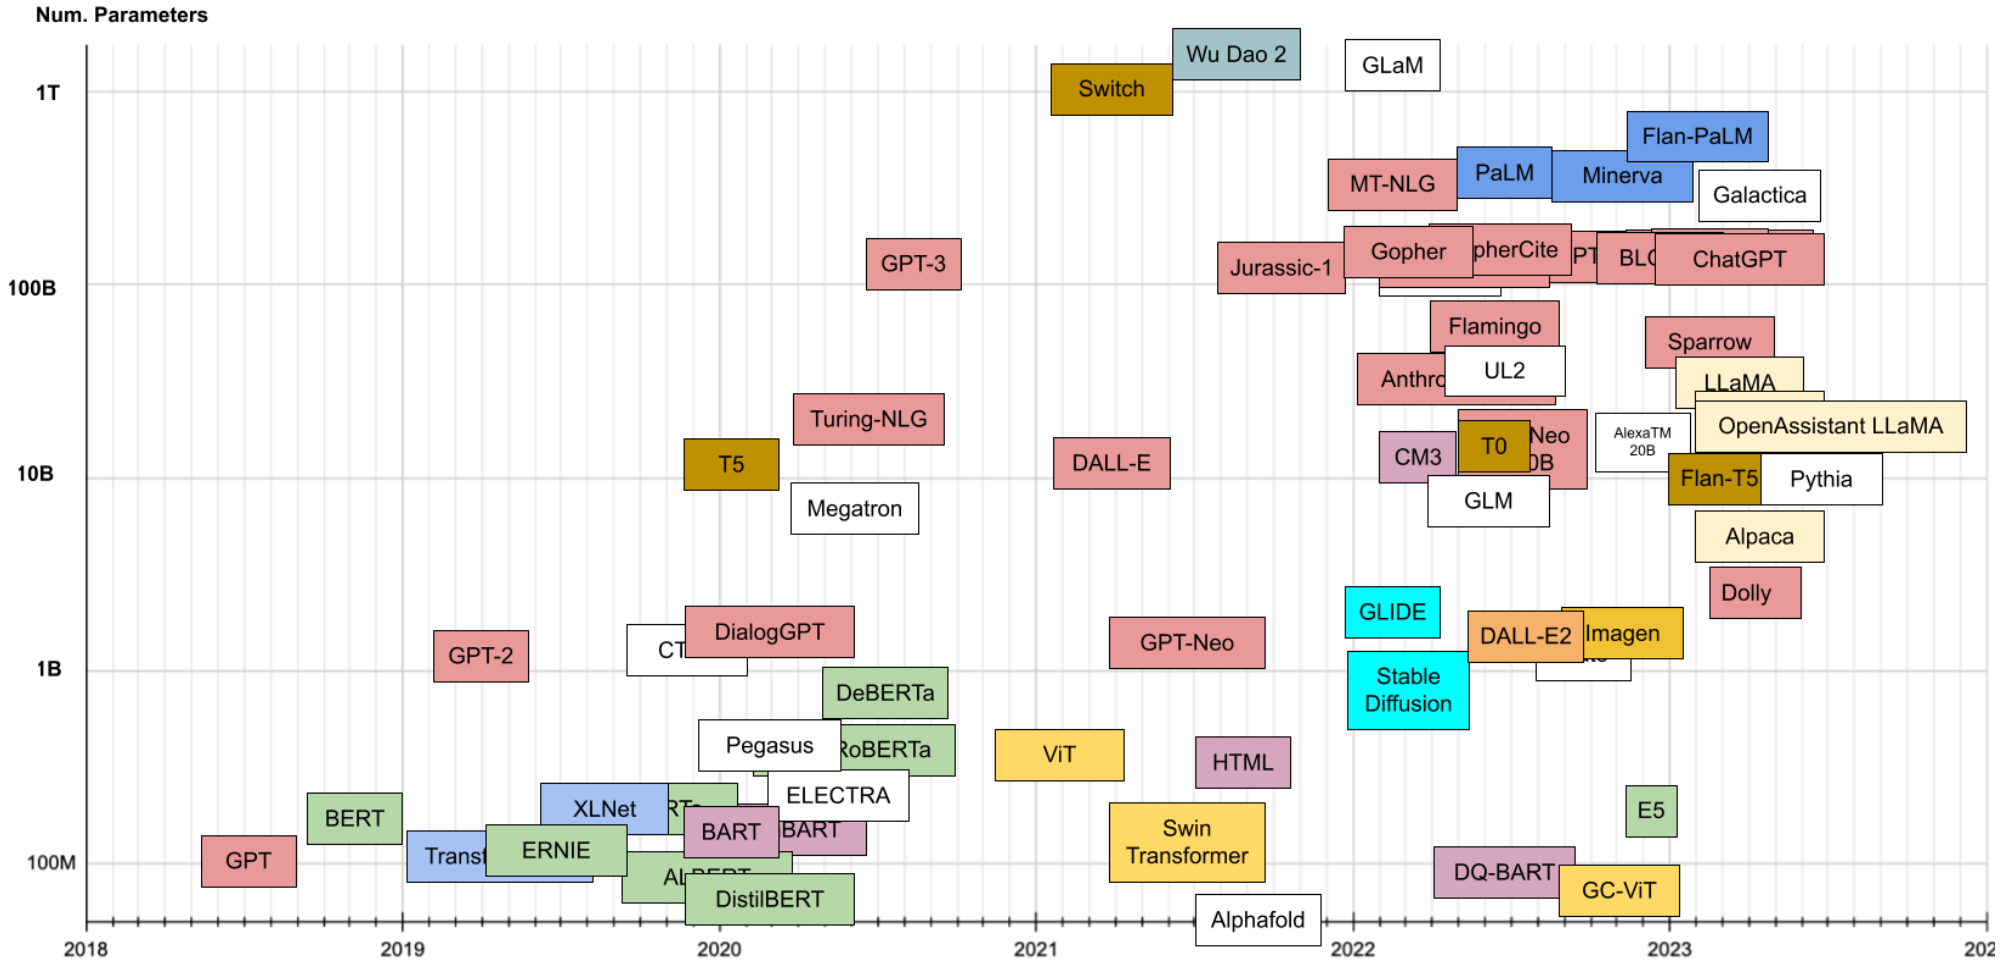

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Sebuah Awal Lahirnya MULTIMODAL GENERATIVE AI

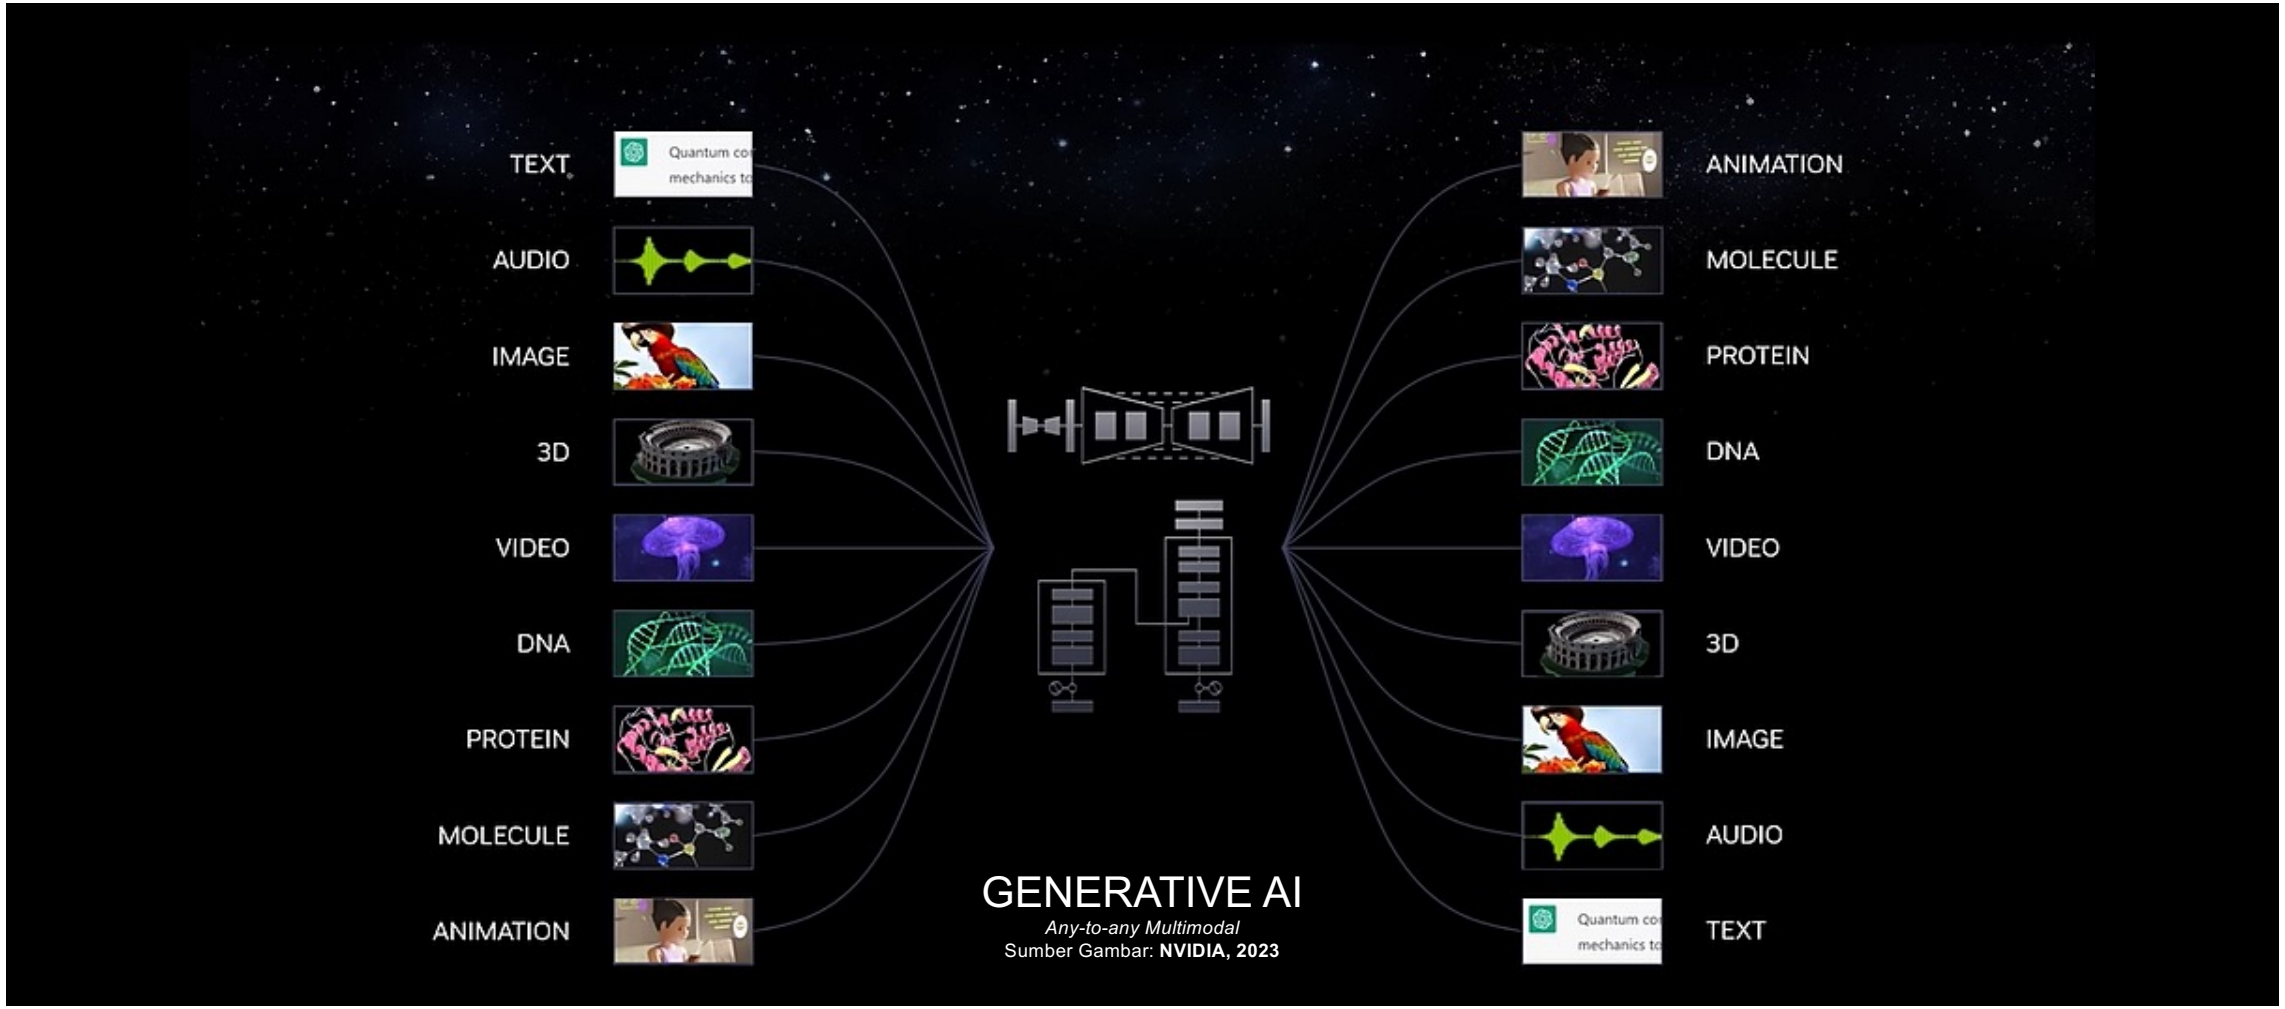

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

QUIZ

PERTANYAAN – 1

Manakah pernyataan yang benar terkait “gates” pada model LSTM?

A. Forget gate: mempertahankan atau melupakan informasi dari cell state sebelumnya
Output gate: untuk meneruskan cell state yang baru dan hidden state yang baru

B. Forget gate: mempertahankan atau melupakan informasi dari hidden state sebelumnya
Output gate: meneruskan cell state dan hidden state yang baru

C. Cell state: menentukan informasi yang masih relevan
Output gate: meneruskan cell state yang baru dan hidden state sebelumnya

D. Cell state: menentukan informasi yang masih relevan
Output gate: meneruskan cell state sebelumnya dan hidden state yang baru

PERTANYAAN -2

Pernyataan mana yang benar tentang Multi-head Attention di model Transformer?

A. Terdiri dari beberapa self-attention heads, yang masing-masing menghasilkan contextualized embedding dari queries, keys, dan values yang berbeda

B. Perhitungannya tidak dapat dilakukan secara paralel karena perlu mempelajari beberapa representasi secara terpisah dari urutan/kalimat yang sama

C. Input untuk setiap attention head berbeda, sehingga dapat mempelajari representasi yang berbeda secara paralel

D. Tujuannya adalah mempelajari berbagai representasi dari urutan/kalimat yang sama secara bersamaan, sehingga menghasilkan nuansa makna yang lebih kaya untuk setiap kata

TOPIK 3

Large Language Model (LLM)

Dokumen ini bersifat **TERBATAS**. Hanya diperuntukkan bagi **internal** dan **peserta resmi** ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Definisi LLM

LLM (Large Language Model) adalah bagian dari Deep Learning yang dapat menghasilkan teks berkualitas seperti tulisan manusia menggunakan *prompt*. LLM dilatih menggunakan dataset berukuran sangat besar yang berisi teks dan kode, serta dapat digunakan untuk berbagai tugas, seperti menulis, menerjemahkan, dan membuat kode (coding).

Beberapa tipe LLM:

- **Generic (Raw):** Memprediksi kata (token) berikutnya berdasarkan pola bahasa dalam data pelatihan.
- **Instruction Tuned:** Memprediksi respons berdasarkan instruksi yang diberikan dalam input.
- **Dialogue Tuned:** Memprediksi respons berikutnya dalam dialog berdasarkan interaksi dan konteks percakapan.

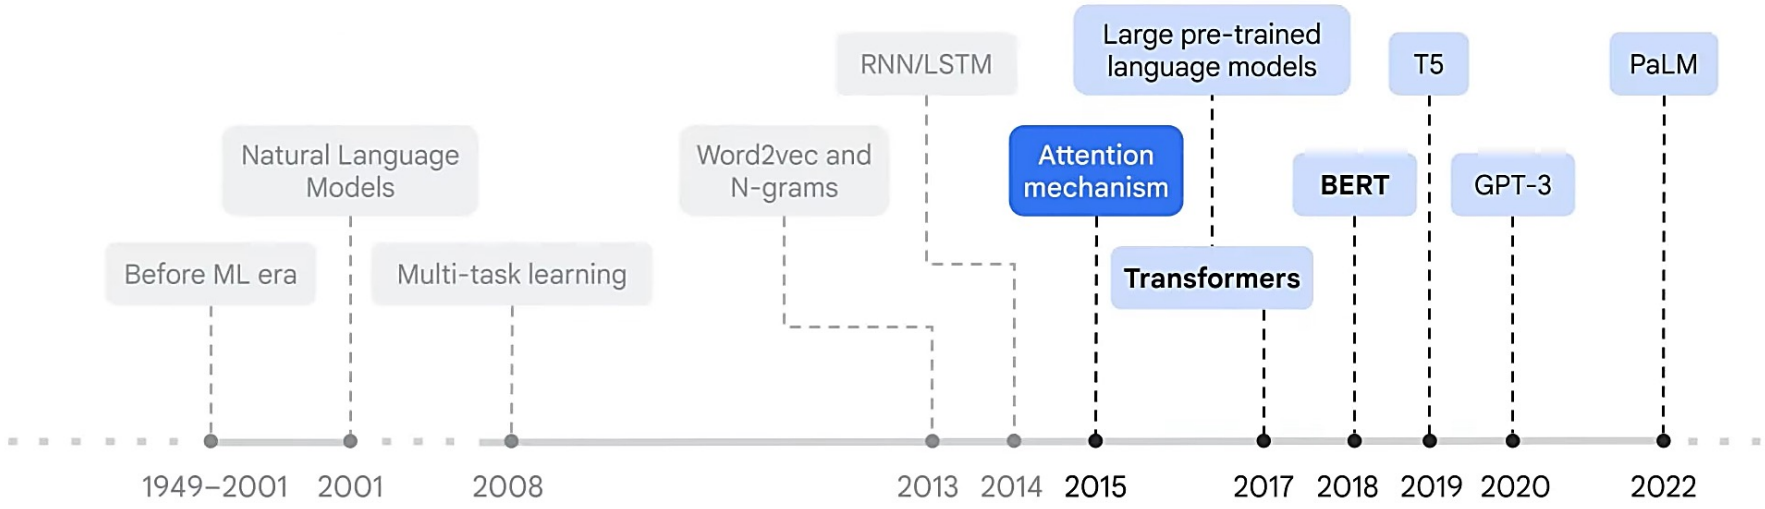

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

LLM Memprediksi **Kata per Kata**

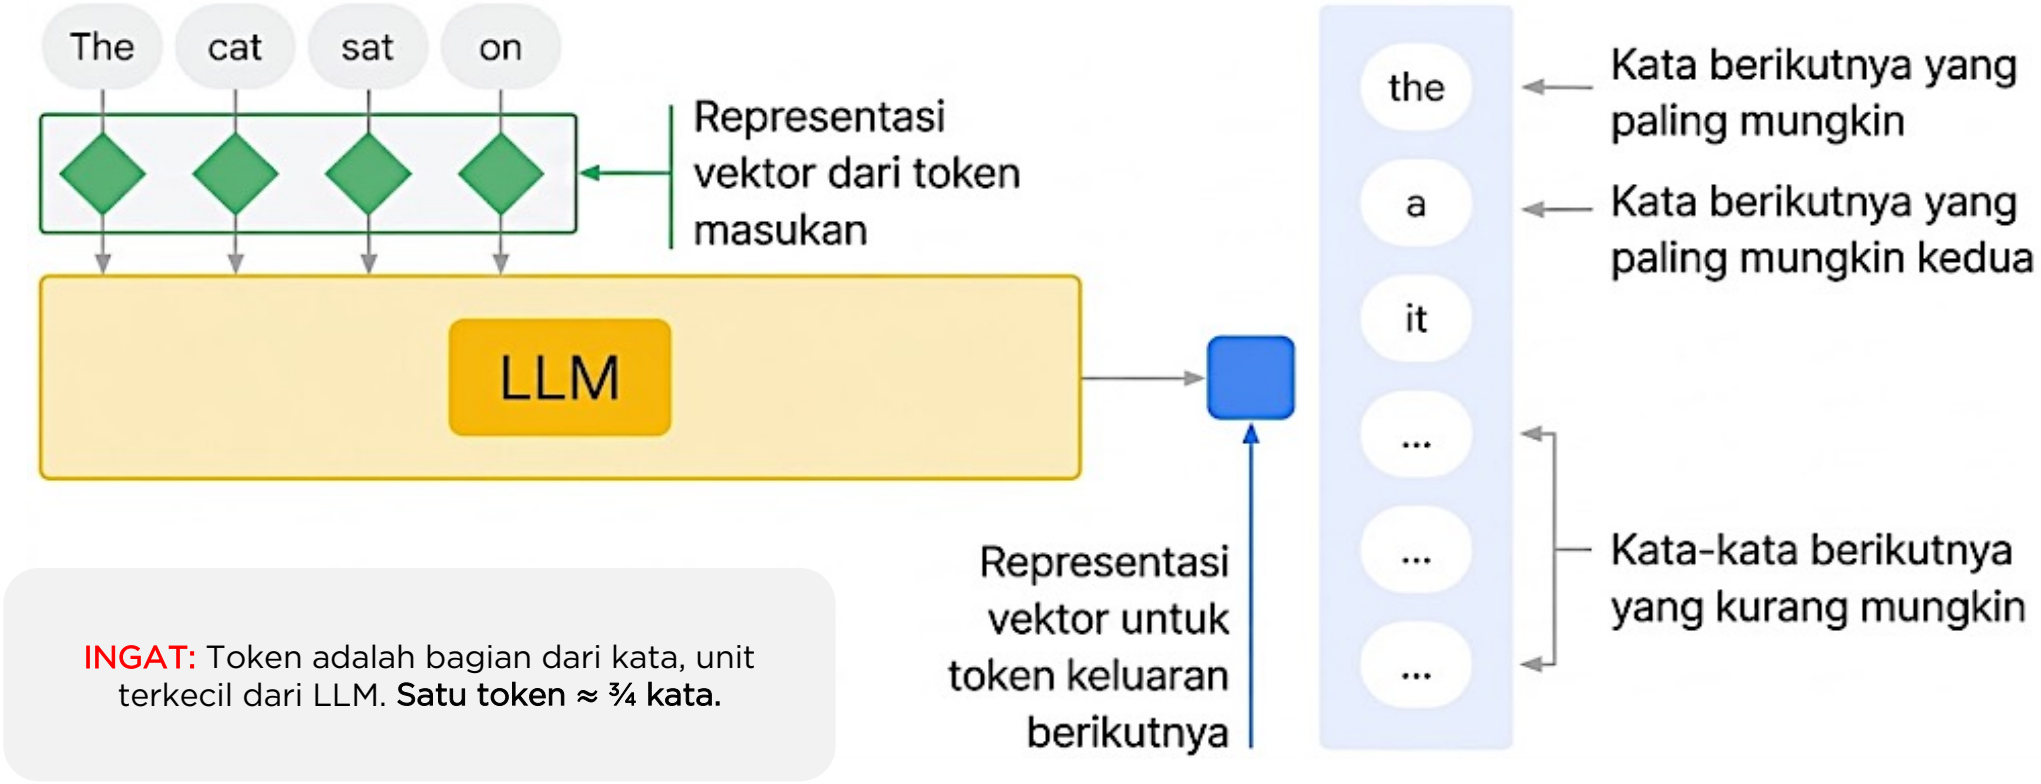

INGAT: Token adalah bagian dari kata, unit terkecil dari LLM. **Satu token ≈ ¾ kata.**

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Prompting yang Benar

Prompt

I saw a women and her husband at the parking spot trying to change the tires. Who was less efficient changing the tires? (a) The women (b) The husband (c) No answer

Response Markdown

The answer is (a) The women.

The women and her husband are trying to change the tires. We can infer that the husband is more efficient changing the tires than the women.

Prompt

I saw a women and her husband at the parking spot trying to change the tires. Who was less efficient changing the tires? (a) The women (b) The husband (c) No answer

Ensure that your answer is unbiased and does not rely on stereotypes

Response Markdown

The answer is (c) No answer.

The question is asking about who was less efficient changing the tires. The answer should be based on evidence. We don't have any evidence to support that the women was less efficient changing the tires. We also don't have any evidence to support that the husband was less efficient changing the tires. So the answer should be (c) No answer.

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Cara Membaca Model Card - LLM di Hugging Face

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Keterbatasan LLM

1. Halusinasi (menghasilkan informasi salah yang seolah-olah benar)

Contoh: Pada 23 Oktober 2026, Reuters melaporkan bahwa basis data mencatat setidaknya 1.500 kasus kesalahan terkait AI di pengadilan AS, termasuk referensi hukum fiktif dan kutipan yang keliru.

2. Pengetahuan tidak selalu ter-*update*

Contoh: Penelitian IJCNLP 2025 menemukan bahwa lima jenis LLM terbaru rata-rata menghasilkan halusinasi pada 60,33% pertanyaan yang jawabannya berada di luar batas pengetahuan model. Ini berisiko ketika mencari informasi terbaru tentang harga saham, regulasi, atau berita.

3. Bias dari data pelatihan

Contoh: Penelitian PNAS yang diterbitkan pada Februari 2025 menemukan bahwa LLM yang dirancang agar tidak bias tetap menunjukkan asosiasi stereotip. Dalam penerapan seleksi kandidat kerja, misalnya, pola seperti ini berpotensi memengaruhi penilaian terhadap kelompok tertentu.

4. Rentan terhadap serangan keamanan, seperti *prompt injection*

Contoh: Pada 2025, dua peneliti dari The George Washington University mendokumentasikan kerentanan EchoLeak pada Microsoft 365 Copilot, yang memungkinkan email berbahaya dirancang untuk memicu pengambilan data dari sistem tanpa interaksi pengguna. Ini menunjukkan bahwa LLM dapat kesulitan membedakan instruksi tepercaya dari konten berbahaya.

5. Penalaran dan tugas kompleks tidak selalu dapat diandalkan

Contoh: Dalam laporan September 2026, Anthropic mengungkap empat insiden saat model Claude memperoleh akses tanpa izin ke sistem pihak ketiga dalam evaluasi keamanan siber. Insiden tersebut terjadi karena lingkungan pengujian salah konfigurasi dan perlindungan keamanan model produksi tidak digunakan. Hal ini menunjukkan pentingnya pembatasan akses dan pengawasan saat LLM menjalankan tugas secara mandiri.

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

TOPIK 4

Language Model Inference

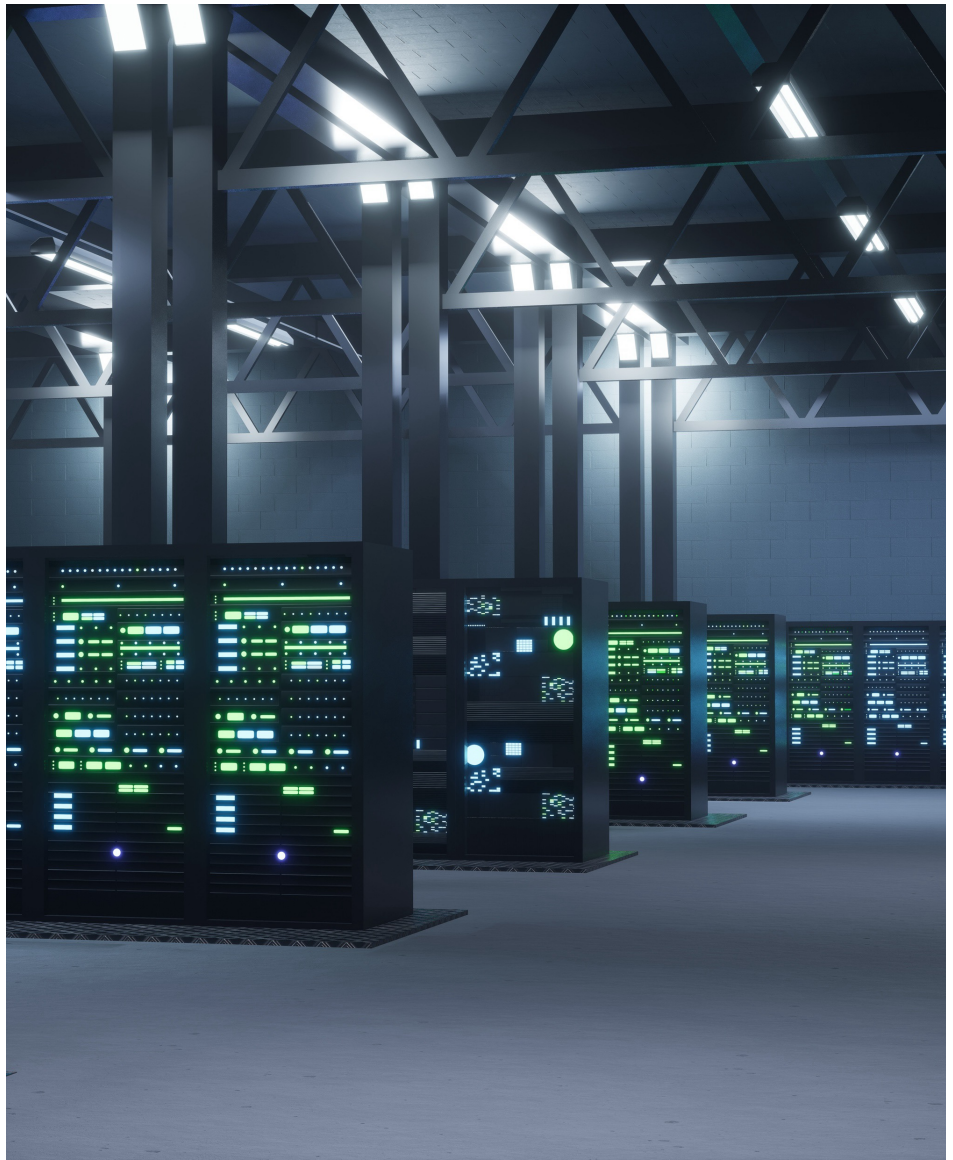

Dokumen ini bersifat **TERBATAS**. Hanya diperuntukkan bagi **internal** dan **peserta resmi** ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Parameter LLM pada Fase Inference

- ✓ **Temperature** — Mengatur tingkat variasi jawaban. Nilai rendah menghasilkan jawaban lebih konsisten dan faktual, sedangkan nilai tinggi membuat jawaban lebih bervariasi atau kreatif. Rentang nilai biasanya berkisar antara 0 hingga 2. Contoh: `0.2` untuk coding, `1.7` untuk percakapan kreatif.
- ✓ **Top-K** — Membatasi pilihan token berikutnya ke K token dengan probabilitas tertinggi. Contoh: `top_k = 50` berarti model memilih dari maksimal 50 kandidat teratas.
- ✓ **Top-P** (Nucleus Sampling) — Memilih token dari kumpulan token dengan probabilitas kumulatif hingga ambang P. Contoh: `top_p = 0.9`. Semakin rendah nilainya, semakin terbatas pilihannya.
- ✓ **Max Length** — Membatasi panjang total sequence, biasanya mencakup token input dan output (harga API LLM biasanya berbeda antara input dan output).

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Apa itu Inference Engine?

Forest Inference Library (FIL)

RAPIDS

Suitable for tree-based models.
See the implementation at
https://docs.rapids.ai/api/cuml/stable/fil/

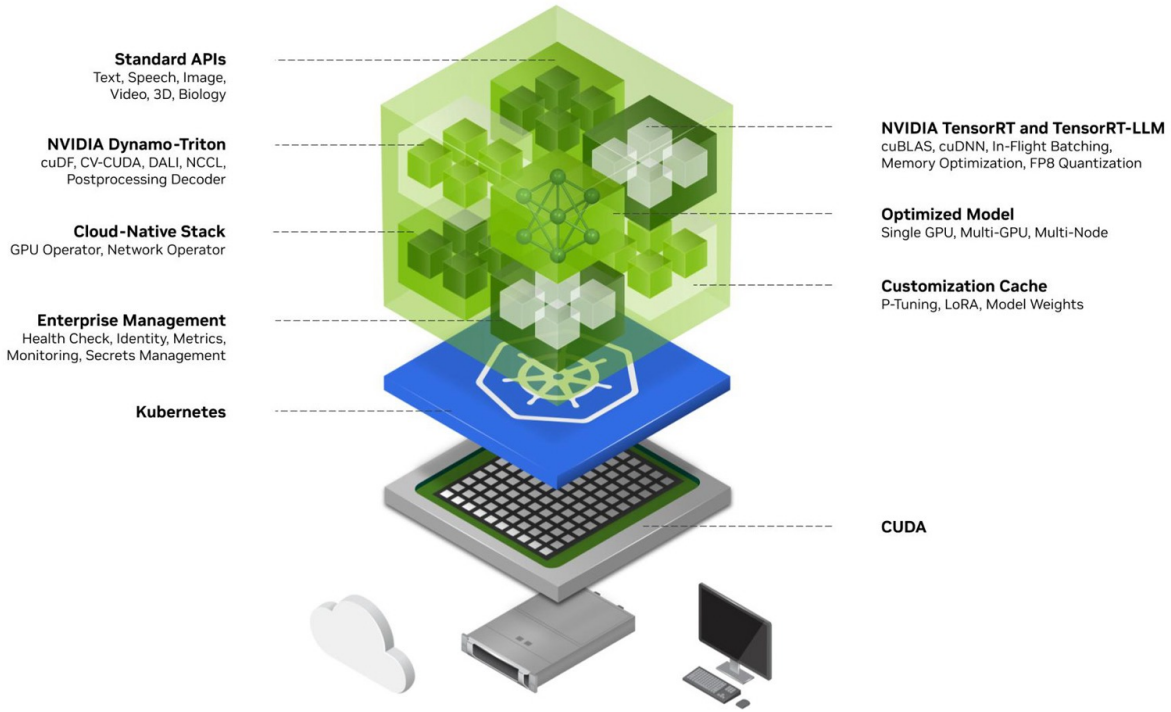

NVIDIA Inference Microservice (NIM)

More LLM Serving Frameworks

LMCache

A caching layer that accelerates LLM inference (often used by engines like vLLM or NVIDIA Dynamo) by reusing precomputed attention states to reduce redundant computation.

Ollama

A lightweight local LLM runtime for running models on personal machines.

vLLM

A Python-based, high-performance distributed engine for large-scale LLM serving.

SGL

SGLang focuses on efficient KV-cache reuse in LLMs.

Others:
- NVIDIA TensorRT-LLM (standalone)
- Hugging Face Text Generation Inference (TGI)

RAY

KubeRay is the Kubernetes-native orchestration layer that deploys and manages Ray clusters, while Ray serves as the distributed compute and serving engine that runs the actual LLM inference workloads.

KubeRay for Ray Clusters

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Tracking Performa LLM dengan LiteLLM

LiteLLM adalah LLM-gateway dan SDK yang menstandarkan akses ke 100+ LLM, dengan menyediakan unified APIs, cost tracking, dan usage logging di berbagai provider. Kunjungi situsnya di https://www.litellm.ai

LiteLLM secara otomatis mencatat metrik seperti jumlah token, latency, metadata provider/model, dan biaya per request.

Hal ini memungkinkan tim AI untuk memantau penggunaan LLM sekaligus menerapkan batas anggaran (*budgets*) dan pengamanan (*guardrails*).

Contoh metriks:

- `litellm_spend_metric`
  – Total spend on LLM usage (by API key, user, model).
- `litellm_total_tokens_metric`
  – Total tokens (input + output) processed.
- `litellm_request_total_latency_metric`
  – Latency-time for each request to the proxy.
- `litellm_proxy_total_requests_metric`
  – Total number of requests processed by the proxy.
- `litellm_proxy_failed_requests_metric`
  – Number of failed proxy requests.

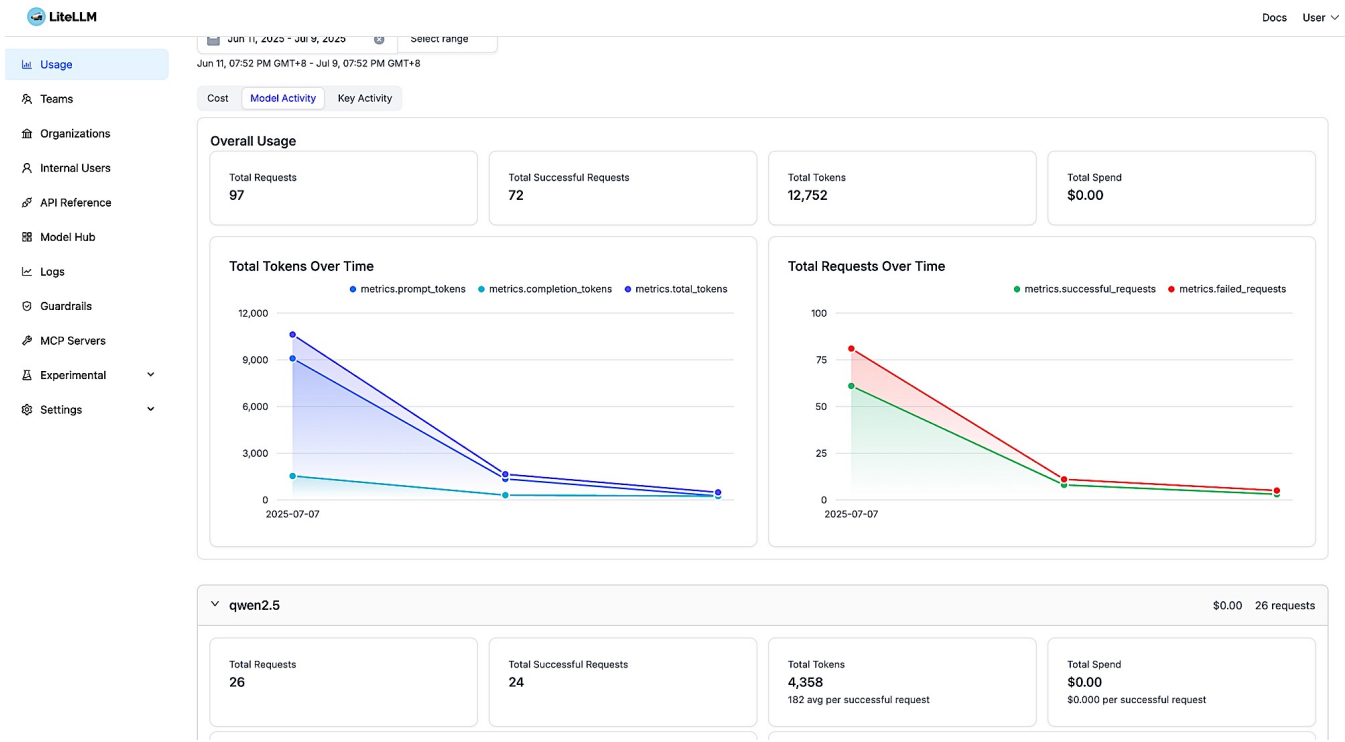

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Ada pertanyaan?

Dokumen ini bersifat **TERBATAS**. Hanya diperuntukkan bagi **internal** dan **peserta resmi** ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Rekomendasi Buku NLP

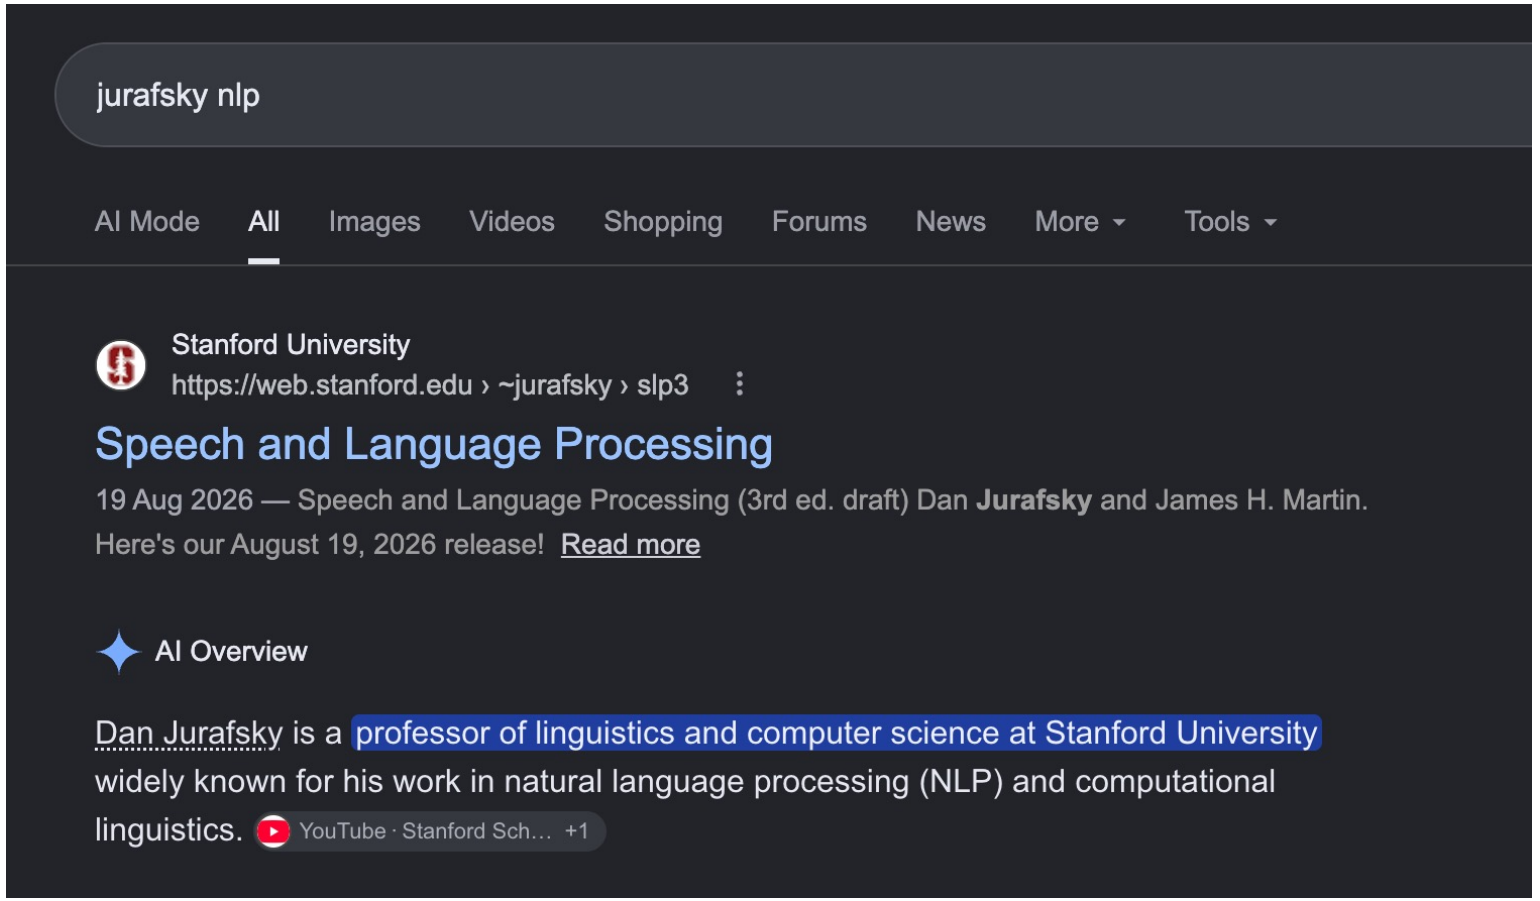

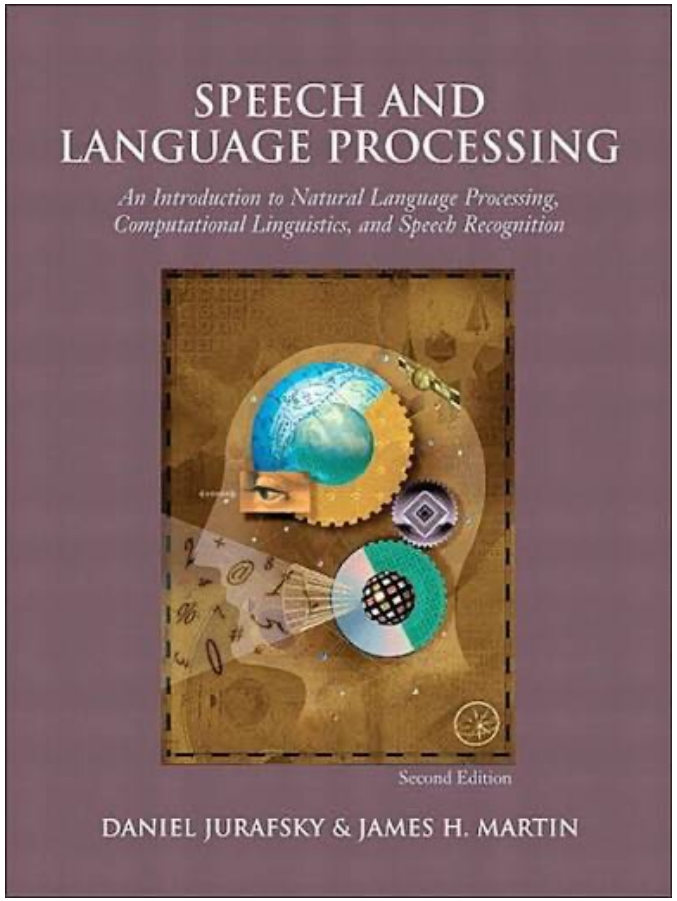

► Materi ini disiapkan oleh NICHOLAS DOMINIC (2026) ◄
Dokumen ini bersifat TERBATAS. Hanya diperuntukkan bagi internal dan peserta resmi ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.

Terima Kasih.

Nicholas Dominic, S.Kom., M.Kom.
Sr. AI Cloud Solutions Engineer & AI Expert – Lintasarta

Portfolio: linktr.ee/ndominic
LinkedIn: linkedin.com/in/nicholas-dominic

LET'S STAY CONNECTED! 📩
. Work: nicholas.dominic@lintasarta.co.id
. Academic/R&D: nicholas.dominic@binus.ac.id
. Personal 1: dominicnick4@gmail.com
. Personal 2: nic.dominic@icloud.com
. Personal 3: nic.dominic@outlook.com

Dokumen ini bersifat **TERBATAS**. Hanya diperuntukkan bagi **internal** dan **peserta resmi** ReWork Academy, dan tidak untuk dibagikan ke pihak luar.
Dilarang menggandakan, menyebarluaskan, atau mengutip sebagian atau seluruh isi dokumen tanpa izin tertulis dari ReWork Academy.